

Microsoft Foundry を SI で使う

技術選定とアーキテクチャ判断の基準

2026-08 / 課内勉強会

本リポジトリの調査(survey)+実装検証(labs)の入口となる資料



今日のゴール — 持ち帰る 3 つの判断能力

	判断能力	中身
①	決める順序	後戻りコストの大きい順に 5 つのゲート(G1～G5)で閉じる
②	当たりの付け方	要件の言葉 → ユースケース別パターン+選定 3 軸で構成候補を 1～2 案に絞る
③	見積もりの現実	「Foundry がやってくれないこと」と廃止期限を工数・リスクに乘せる

- この資料は**入口(1 層目)**。各スライド下部のリンクから詳細ドキュメント(**2 層目**)に降りられる
- 全機能の暗記は不要 — 「どこを見れば載っているか」が分かれば提案は書ける

2 層目の全体像: [survey/README.md](#) — docs/survey/README.md

Microsoft Foundry SI 勉強会 — 詳細: docs/survey/ 配下(各スライド下部のリンク参照)

この資料群の地図 — 調査と実証を分けて積んである

資料	答える問い	更新サイクル
features(機能一覧)	その機能は 使えるのか (GA / プレビュー、約 200 機能+出典 URL)	月次
architecture(設計ガイド)	どう組むか (公式リファレンス+ユースケース別パターン+運用・移行)	四半期
proposal(提案実務)	どう提案するか (ヒアリング・コスト手順・日本規制・公開事例)	随時
tech-selection-guide	実装で 実証 できたことだけ(labs 由来・調査と混ぜない)	検証ごと
labs/maf-ports	動くコード 14 本+オフラインテスト約 470 件	—

- **出典分離の方針**: 「公式ドキュメント調査(survey)」と「実装検証(labs)」を混ぜない。提案書では「公式ガイド
ンス準拠+実装検証済み」の二本立てで根拠を示せる

詳細: [features](#) / [architecture](#) / [proposal](#) / [tech-selection-guide](#) — docs/survey/README.md

前提合わせ: 2025-11 Ignite の大改編で名前が全部変わった

観点	旧	現行
ブランド	Azure AI Studio / Azure AI Foundry	Microsoft Foundry
ブランド	Azure AI Services	Foundry Tools
エージェント API	Assistants API(Threads / Runs)	Responses API(Agents v2)
用語	Threads / Messages / Runs / Assistants	Conversations / Items / Responses / Agent Versions
リソースモデル	Hub + Azure OpenAI + AI Services	Foundry リソース(単一)
SDK	<code>azure-ai-inference</code> 等 複数	<code>azure-ai-projects 2.x</code> + <code>openai</code>
ドキュメント	<code>/azure/ai-foundry/</code>	<code>/azure/foundry/(新)+ /azure/foundry-classic/(旧)</code>

- 検索で出てくる情報の大半は旧名義。この対応表を頭に入れて読まないと、廃止済み API の記事で設計してしまう

詳細: [features/index\(前提知識の節\)](#) — docs/survey/features/README.md

Foundry の構成要素マップ(features の 8 カテゴリ)

#	カテゴリ	主な中身
01	プラットフォーム基盤	Foundry リソース / プロジェクト / RBAC / ネットワーク / CMK / IaC
02	モデル	カタログ(OpenAI / Claude / Grok 等)/ デプロイタイプ / Model router / Foundry Local
03	Agent Service	Agents v2(Responses API)/ prompt・hosted エージェント / Memory / Routines / A2A
04	ツール・ナレッジ	File Search / AI Search / Web search / MCP / Toolbox / Foundry IQ
05	観測・評価	トレーシング / 評価器 / クラウド評価 / AI Red Teaming / モニタリング
06	ガードレール	コンテンツフィルター / Prompt Shields / Groundedness / PII
07	Foundry Tools	Speech(Voice Live)/ Document Intelligence / Content Understanding
08	開発者サーフェス	v1 API / SDK / CLI / Bicep / Microsoft Agent Framework / LangGraph 統合

- 機能ごとの GA / プレビュー+サーフェス別対応(ポータル / CLI / SDK / REST)を全行出典つきで整理済み

詳細: [features/index](#) — docs/survey/features/01~08-*.md

「GA だが足元が動いている」を読む(SI 選定観点の要点)

- 新ポータルは GA、ただし機能単位で GA / プレビューが混在。体系的な一覧は公式の [Feature readiness at GA](#) が唯一 — 提案前に必ず引く
- **Agent Service** はサービスとして GA。しかし hosted agents は 2026-08-20 に初期レビュー基盤終了(再デプロイ必須)、ビジュアル Workflows は 2026-12-01 廃止 — 「GA だが足元が動いている」状態
- **CLI** は一級市民ではない。専用の `az foundry` は存在しない。多くの機能が「ポータル + SDK / REST のみ」 — 自動化の見積もりに直接効く
- **Claude(Anthropic)**が本格参入(GA)。ただし Anthropic SDK + Marketplace 課金 + Foundry 組み込みコンテンツフィルター非適用という独自制約つき

詳細: [features/index\(ハイライトの節\)](#) — [docs/survey/features/README.md](#)

Microsoft Foundry SI 勉強会 — 詳細: [docs/survey/](#) 配下(各スライド下部のリンク参照)

公式リファレンスアーキテクチャは 3 本しかない


	名称	位置づけ
公式-A	Basic Chat	PoC 専用。記事自身が本番非推奨と明言
公式-B	Baseline Chat	本番の出発点。WAF が「AI ワークロードの推奨アーキテクチャ」と名指し(図 →)
公式-C	Baseline in ALZ	hub-spoke 版。実装コードは記事から削除済み(AI Landing Zones は Preview)

- それ以外の公式ページは「ガイド」「ソリューションアイデア」で検証レベルが下がる — 顧客提案での引用時は区別する

詳細: [architecture/01-official-baselines](#) — docs/survey/architecture/01-official-baselines.md

Official-B: Baseline Microsoft Foundry Chat (AAC reference architecture)

Network-isolated, single-region, zone-redundant. Named by WAF as the recommended architecture for AI workloads. Production starting point.



→ data / control - - - telemetry (OTel) auth billing note Source: AAC baseline-microsoft-foundry-chat -> docs/survey/architecture/01
 Web search tool calls api.bing.microsoft.com internally and BYPASSES the egress subnet -> validate every tool against egress policy (stated in the article).
 No built-in DR: no state replication / backup / PITR in Agent Service -> recovery = rebuild (mitigate: Cosmos PITR, agent-as-code, user-assigned ML delete locks).
 Top costs: Cosmos DB / AI Search / DDoS Protection, then UI compute + App Gateway. Agents call tools non-deterministically -> external API cost can spike.
 Auth: user -> Entra ID / App Service & prompt agents -> shared project managed identity (split projects per access pattern) / per-user conversation authz = app responsibility (BOLA)

判断① 決定は「後戻りコストの大きい順」に閉じる

ゲート	問い	これで決まるもの
G1 データ・規制	そのデータを、どこで、誰に処理させてよいか	モデル・デプロイタイプ・外部ツール可否
G2 ネットワーク	閉域か、パブリックか	使える Foundry 機能の一覧(後付け不可)
G3 制御	明示的な状態遷移・承認・再開が要るか	ポータル完結か、コードファーストか
G4 統合	既存システムとの主従はどちらか	プラットフォームとして使うか、部品として使うか
G5 ライフサイクル	いつまで、誰が保守するか	プレビュー可否・IaC の作り込み度

- 機能比較表から入ると G1 / G2 の手戻りで壊れる。**上から順に閉じるのがこのガイドの背骨**

G1 / G2 は後付けできない — 最初のヒアリングで確定させる

- **BYO VNet 注入(閉域構成)は作成後の変更不可**。後から閉域要件が出ると作り直し — アンチパターンの代表格
- 閉域では **File Search / Traces / Memory / Work IQ / Browser Automation / Image Generation 等が使えない**。「閉域で使えない機能の一覧」から設計を始める
- 「**日本国内でデータ処理を完結**」= **Regional Standard(Japan East)のみ**。APAC Data Zone は日豪韓星印で処理されうるため不可
- **Web search / Grounding with Bing は DPA 対象外・別課金**(データがコンプライアンス境界の外に出ると明記) — 規制業種では原則不可として扱う

詳細: [architecture/07-usecase-regulated-edge](#) — docs/survey/architecture/07-usecase-regulated-edge.md

G3～G5 と、11 章の結論「机上で当たりをつけられる」

- **G3 制御:** 分岐・ループ・承認・再開の明示制御が要るならコードファースト。CAF も「クリティカルな業務ロジックには決定的ワークフローを強制せよ(Foundry / MAF)」と名指し
- **G4 統合:** 既存システムが主なら「モデルとツールだけ借りる」構成(Responses API のみ)。ただし Foundry の Tracing / Evaluations 等の運用機能は使えなくなる
- **G5 ライフサイクル:** 顧客内製・非開発者運用ならポータル中心。レビュー許容度もここで確定
- 「複数試作して比較するしかない」は誤り(CAF が Skip prototyping: Yes と明言)。プラットフォーム・単一 vs マルチ・パターンは机上で決まる。実測が要るのは品質・コスト実額だけ — そこは評価ハーネスで回帰可能にする

判断② ユースケース別パターン全体マップ(A1～E6)

詳細: [architecture/index](#) — docs/survey/architecture/README.md(完全版は付録 A1)

ID	パターン	主な決め手
A1	部門内 FAQ チャット	File Search 最小構成。速度優先・権限制御なし
A2	全社ナレッジ検索(本番)	ユーザーごとに見える文書が違う(本番の標準形)
A3	既存 AI Search 資産の活用	索引設計を自分で持ち続けたい
A4	M365 / SharePoint 主データ源	権限透過。M365 Copilot ライセンス前提
A5	複数ソース横断・高精度	Foundry IQ(agentic retrieval)
B1	単一エージェント+基幹 API	参照系中心
B2	承認付き業務自動化(HITL)	「担当者が承認してから実行」(MAF hosted agent)
B3	長時間・確実な再開	数時間～数日停止して再開(Durable + DTS)
B4	マルチエージェント(専門分化)	領域ごとに権限を分けたい
B5	業務フローエンジン主導	業務部門がビジュアルで保守(Logic Apps / Copilot Studio)
C1	一般顧客向けチャット	不特定多数(WAF + APIM)
C2	マルチテナント SaaS	複数顧客に販売(APIM 事実上必須)
C3	大規模・複数部門への払い出し	部門別按分・キャパシティ
D1	規制業種・閉域	BYO VNet。閉域・監査・データ主権
D2	ソプリン(Azure Government)	hosted agent・MCP・A2A 非対応に注意
D3	エッジ・オンプレ	Foundry Local / Azure Local 版 / 切断コンテナ
E1	音声エージェント	Voice Live(SIP 非対応)
E2	文書処理・IDP	DI(定型)/ Content Understanding(非定型)
E3	大量バッチ処理	Batch で 50% 割引
E4	マルチモーダル生成	画像・動画。閉域不可
E5	M365 / Teams 連携	業務ツール内で使わせる
E6	ファインチューニング運用	挙動・文体はモデル側、知識追加は RAG

A: 社内ナレッジ検索・RAG — 本線は A1 → A2


- A1(File Search 最小構成)で PoC → 品質が出なければ A2 が定石
- 「部署によって見える文書が違う」→ A2 一択(GA 要件を満たす唯一の方式)
- File Search は埋め込み・チャンク設定が固定 — 日本語の長文・表主体文書で品質が出ないことがある
- PoC 段階で難しい文書 20~30 件の検索品質を測ってから方式を確定する

詳細: [architecture/04-usecase-chat-rag](#) — docs/survey/architecture/04-usecase-chat-rag.md

Microsoft Foundry SI 勉強会 — 詳細: docs/survey/ 配下(各スライド下部のリンク参照)

A2: Company-wide knowledge search — own AI Search index (production standard)

Per-user document visibility (security filter / ACL). You own chunking, embeddings, metadata; integrated vectorization + semantic ranker stay managed.



→ data / control - - - -> telemetry (OTel) auth billing note Source: docs/survey/architecture/04 A2 (closed-network variant: ch.07)
Chunk strategy is a semi-permanent choice (official wording) - re-chunking means full re-index. Decide chunk size / overlap / language analyzer up front.
Semantic ranker reranks TOP-50 only (L1 recall failures cannot be rescued); vector index quota per partition is a hard limit (Basic 5GB / S1 35GB / S2 150GB / S3 300GB).
Doc-level ACL: security filter (GA, group IDs in index) or query-source-authorization (preview) - see ch.04 for the 4 options.
Auth: user -> Entra ID / agent -> AI Search via managed identity + PE / per-user visibility enforced in the query, never in the prompt

RAG の 5 分岐 — どこにナレッジを持たせるか

パターン	選ぶとき	注意
A1 File Search	手軽・小規模・静的データ	設定固定・権限制御なし
A2 AI Search 自前索引	本番の標準形 。セキュリティリミシング必須のとき	索引設計・運用は自前
A3 AI Search ツール直結	既存の索引資産を活かす	索引設計を持ち続ける覚悟
A4 SharePoint ツール	M365 が主データ源・権限透過	プレビュー+Copilot ライセンス or 従量課金
A5 Foundry IQ	複数ソース・複数エージェントで共有	一部 GA・ポータル体験はプレビュー

- **Azure OpenAI On Your Data は 2026-10-14 廃止**。「モデルが直接データを読む」構成の既存提案書は要更新(移行先: Agent Service + Foundry IQ)

C: 顧客向け公開・マルチテナント — 境界防御はアプリ側の責務

- C1 一般公開: WAF のチューニングと BOLA 対策を工数に入れる — 会話 ID のユーザー単位認可を Foundry はやってくれない(ID を知られると他人の会話を読める)
- C2 マルチテナント SaaS: APIM が事実上必須。テナント別のトークン計測・課金按分は APIM の `llm-emit-token-metric` で自前実装
- C3 大規模・複数部門: クォータはデプロイ単位 — 1 デプロイ共有だと 1 つの暴走が全体を止める。部門別デプロイ分割か APIM のレート制限で切る
- 429 のリトライ / バックオフはアプリ側の必須実装

詳細: [architecture/06-usecase-customer-facing](#) — docs/survey/architecture/06-usecase-customer-facing.md

D: 規制業種・閉域・エッジ

- D1 閉域(☒ →): BYO VNet + standard setup(BYO 3 点)+ PE 群
- 設計の出発点は「閉域で使えない機能の一覧」(File Search / Traces / Memory / 画像生成...)
- 固定費(Firewall / PE / APIM)が月額の下限を決める — 小規模の閉域案件はトークン代より固定費
- D2 Gov: hosted agents・MCP・A2A 非対応
- D3 エッジ 3 形態: Foundry Local(端末・GA)/ Azure Local 版(申請制)/ 切断コンテナ


詳細: [architecture/07-usecase-regulated-edge](#) —

[docs/survey/architecture/07-usecase-regulated-edge.md](#)

Microsoft Foundry SI 勉強会 — 詳細: [docs/survey/](#) 配下(各スライド下部のリンク参照)

D1: Regulated industry / closed network — BYO VNet (standard agent setup)

Design starts from the list of features that do NOT work in a closed network. This gate cannot be retrofitted (setup is immutable after creation).



→ data / control - - - -> telemetry (OTel) auth billing note Source: docs/survey/architecture/07 (BYO VNet / standard agent setup)

NOT available in closed network: File Search / Memory / Work IQ / Logic Apps tool / Browser Automation / Computer Use / Image Generation.
Tracing VNet support is inconsistent across official pages -> assume unsupported. Consequence: RAG / memory / observability all self-built ('closed + full managed' does not exist).
capability host cannot be updated after creation -> config change = delete & recreate (agents lose conversations/files). IaC must assume rebuild.
Auth: Entra ID only end-to-end. TLS inspection on the egress firewall BREAKS agent connections - conflicts with common JP-FSI SSL-visibility policy: get the exception approved early.

E: チャット以外の類型 — 音声・文書処理・バッチ・M365

ID	類型	使うもの	落とし穴
E1	音声エージェント	Voice Live API	SIP 非対応・ガードレール非適用。Japan East はネイティブ音声モデル非提供
E2	文書処理・IDP	DI(定型帳票)/ Content Understanding(非定型)	CU は BYO モデル接続必須・ページ課金
E3	大量バッチ	Batch デプロイ	50% 引きだが 24h ターゲット・SLA なし
E4	画像・動画生成	非同期ジョブ	閉域不可
E5	M365 / Teams 公開	公開フロー(GA)	Bot Service が別途必要
E6	ファインチューニング	MLOps パイプライン	挙動・文体は FT、知識追加は RAG。デプロイは作り直し前提

詳細: [architecture/08-usecase-specialized](#) — docs/survey/architecture/08-usecase-specialized.md

選定は一列比較ではなく「3 つの独立した軸」

- 軸 A: エージェントの定義方法 — 構成のみ(Prompt agent: ポータル / SDK で定義、フルマネージド実行)か、コード(Hosted agent: 自前コードをデプロイ、独自オーケストレーション可)か
- 軸 B: コードを書く場合のフレームワーク — Hosted agent は MAF 専用ではない。MAF / LangGraph / OpenAI Agents SDK / 自前コードが公式サポート。「Foundry を使うか」と「MAF を使うか」は**独立した判断**(LangGraph 製エージェントを Foundry にホストする構成も正規ルート)
- 軸 C: Foundry との統合度 — フル統合 / Responses API のみ利用(モデルとプラットフォームツールだけ借りる。既存システム組み込み型の SI 案件で重要)/ Foundry 非依存

16 レイヤー × M / H / S — 「Foundry 機能を使う vs 自前実装」

#	レイヤー	M(フルマネージド)	H(ハイブリッド)	S(自前)	迷ったら
L1	モデル提供	Foundry モデルデプロイ	+ APIM ゲートウェイ	他クラウド / セルフホスト	M
L2	オーケストレーション	Prompt agent	Hosted agent(MAF・LangGraph)	自アプリ + Responses API	H
L3	会話状態	Conversations	BYO Cosmos DB	自前 DB	M→S
L4	長期記憶	Foundry Memory(プレビュー)	Memory + 自前フィルタ	自前サマライズ + ベクトル検索	S(本番)
L5	ナレッジ / RAG	File Search / Foundry IQ	AI Search + 自前索引	自前パイプライン	H
L6	ツール実行	ツールカタログ / MCP	Toolbox + 自前 MCP	アプリ内 function calling	H
L7	コード実行	Code Interpreter	Custom CI	ACA dynamic sessions 直	M
L8	ガードレール	Guardrails 既定	カスタム	Content Safety API 自前呼び	M+S 併用
L9	ID・認可	Foundry RBAC + Entra	OBO / Agent identity	自前認可基盤	M
L10	ネットワーク	パブリック + Private Link	BYO VNet 注入	自前 VNet	要件次第
L11	ゲートウェイ	クォータのみ	APIM AI ゲートウェイ	自前プロキシ	H
L12	可観測性	Foundry Tracing	OTel 自前計装 → App Insights	自前ログ基盤	M+H
L13	評価	Foundry Evaluations	evals API を CI から	自前ハーネス	H
L14	UI・チャネル	Teams / M365 公開	自作 Web + Responses API	既存システム組込み	要件次第
L15	実行基盤	Hosted agents	Container Apps 等	AKS / オンプレ	H
L16	IaC・CI/CD	ポータル手動	Bicep / Terraform + azd	既存 IaC に統合	S

詳細(各レイヤーの全選択肢と根拠): [architecture/02-building-blocks](#) — docs/survey/architecture/02-building-blocks.md

マルチエージェント協調の分水嶺 — 2 軸 3 値(実装で実証済み)

制御を誰が決めるか(コード / LLM) × 制御が戻るか(戻る / 移る)

型	制御	応答	MAF での器	例
グラフ	コード	—	Workflow(core)	直列・並列・分岐・ループ
相談型(agent-as-tool)	LLM が選ぶ	戻る	Agent + 動的ツール生成	通信制約下の協調
担当交代(handoff)	LLM が選ぶ	移る	HandoffBuilder(別パッケージ・会話型)	サポートのエスカレーション

- そもそも**単一エージェントで始める**(CAF: 最初からマルチにしてよいのは境界・組織・確定拡張の 3 条件のみ。
Anthropic: マルチはトークン 3〜10 倍)
- 実証: 元アプリの「handoff」の多くは**固定シーケンス** — グラフ化で失うものではなく、型・テスト・可視化を得る。
one-shot パイプラインに handoff を使うと順序・終了が確率的になる(Port 7 で比較実装)

詳細: docs/tech-selection-guide.md §1-1 / [architecture/11\(AAC 5 パターンとの対照\)](#)

フレームワーク書き換えコストの実測感(14 移植からの抜粋)

元 → MAF	書き換えの実態
LangGraph(StateGraph)	ノード→Executor、条件エッジ→switch-case。無型共有 dict → 型付きメッセージの規律が強制される
OpenAI Agents SDK(handoff)	構造化出力+switch-case で明示化。1 行 → 数十行だがテスト可能に
AG2 旧 Swarm	長寿命エージェントの「必要悪」がステートレス Agent.run では純関数に縮退
LangChain ルーター(3 DB 振り分け)	三段カスケード約 150 行が Foundry IQ の宣言+プロンプトに消滅。ただし可観測性・単体テスト可能性を失う
ADK + FastAPI(常時稼働)	hosted agent 化で変わるのは周辺 3 点のみ。Routines で cron 配管が不要に

- 共通パターン: 書き換えで元コードの欠陥が見つかる — 型付きグラフへの移植自体がコードレビューとして機能する

作りたいもの → 実証済みコードの対応表(labs/maf-ports)

作りたいもの	実証済みの型	ポート
直列パイプライン	Executor+エッジ、進捗イベント	trend-analysis
並列実行+合流	fan-out / fan-in エッジ	mixture-of-agents
ルーティング / トリアージ	構造化出力+switch-case	research-handoff
自己補正 RAG	採点→分岐→書換のグラフ+AI Search	corrective-rag
評価駆動の品質ループ	サイクリックグラフ+クラウド評価	critique-loop
常時稼働+スケジュール	hosted agent+Routines	hn-briefing-hosted
音声エージェント	Voice Live(3 層分離)	claim-voice-live
ガバナンス / 監査	middleware 3 種+ハッシュ連鎖監査	governed-agent

- 14 ポート合計約 470 テストをネットワークなしで実行 — 「エージェントはテストできない」は設計の問題
- Foundry に載せる最初の動機は観測性 — トレース配線は実質 2 行、ノード・ツール単位のスパンが自動計測

詳細: [labs/maf-ports/README.md\(進捗表\)](#) / [docs/tech-selection-guide.md](#) §3

Microsoft Foundry SI 勉強会 — 詳細: [docs/survey/](#) 配下(各スライド下部のリンク参照)

Foundry が「やってくれないこと」— 頻出トップ 5

#	やってくれないこと	誰が埋めるか
1	リージョン間の自動フェイルオーバー・DR(復旧は再構築)	アプリ層ルーティング+Cosmos 継続バックアップ+再構築パイプライン
2	会話へのユーザー単位認可(BOLA)	アプリ側で所有権をリクエストごとに検証
3	エージェントの blue-green / canary	APIM 等のルーティング層
4	部門・テナント別のトークン計測・課金按分	APIM <code>llm-emit-token-metric</code>
5	コストのハードリミット(公式明記: 機能がない)	予算アラート+自作の自動化

- さらにコンテンツフィルターはフェイルオープンする(フィルター利用不能時はフィルタリングなしで HTTP 200)— 規制業種では `finish_reason` と `content_filter_results` の検証を必須実装にする
- 全 12 項目は付録 A2。提案時に顧客と合意しておく項目として使う

詳細: [architecture/index\(全案件共通の前提の節\)](#) — docs/survey/architecture/README.md

重要期限 2026–2027 — 提案書の賞味期限

期限	対象	設計への効き方
2026-08-20	Hosted agents 初期レビュー基盤	自動移行されない。パッケージ・API・ID がまとめて変わる
2026-08-26	Assistants API / azure-ai-inference SDK	Threads / Runs 前提のアプリは全面改修。状態データは移行されない
2026-10-14	Azure OpenAI On Your Data	「モデルが直接データを読む」構成が終わる。RAG の既存提案書は要更新
2026-12-01	ビジュアル Workflows	ポータルでマルチエージェントを組む構成が消える。長期案件で提案不可
2026-10 前後	gpt-4o / o1 / o3 / o4-mini 等	モデル固定でチューニングしたプロンプトの再検証
2027-03-31	Agents (classic)(v1)	classic プロジェクト上のエージェント資産
2027-04-20	prompt flow	新規開発に非推奨(セキュリティ更新も停止済み)。MAF へ移行
2027-10 前後	FT 済みモデルの deployment	学習停止の約 6 か月後に推論も停止。FT は作り直し前提
2028-09-25	Azure AI Vision Image Analysis	画像解析パイプラインの作り替え
日付未公表	Agent Applications / ハブベース(classic)	廃止予告済み。新規案件で classic を選ぶ理由はほぼない

- PoC → 本番のスケジュールと期限の衝突チェックを提案フローに組み込む(期間内に廃止が到来するなら最初から後継 API で作る)

詳細: [architecture/10-migration-antipatterns / features/index](#)(期限表)

提案・レビューで踏みやすいアンチパターン(11 個から 3 つ)

- 「ポータルで全部できます」と言ってしまう — ポータル完結は「単一 Prompt agent+カタログツール+公開」まで。分岐・ループ・承認の明示制御、ローカルテストは入らない。対処: ポータル完結の範囲とコードが要る範囲の線引き表を提案に添える
- File Search で品質が出ないまま押し切る — 埋め込み・チャンク設定は固定で、日本語長文・表主体の文書に合わないことがある。対処: PoC で難しい文書 20〜30 件を測り、駄目なら早期に AI Search へ(切替コストは後になるほど上がる)
- az CLI で自動化できる前提で見積もる — 専用の `az foundry` は存在せず、多くの機能はポータル+SDK / REST のみ。対処: 自動化は Bicep / Terraform(基盤)+SDK / REST(データプレーン)前提で工数を積む

詳細(全 11 個): [architecture/10-migration-antipatterns](#) — docs/survey/architecture/10-migration-antipatterns.md

実装のハマりどころ(labs での実測から 3 点)

- RBAC 伝播は 5~15 分・ノード間で不均一。さらに Bicep 作成の Foundry プロジェクトは MI にモデルのデータプレーン権限が自動付与されない(ポータル作成は付く) — 401 の原因切り分けで半日溶ける
- データプレーンは Bicep の外。AI Search のインデックス、Memory のストアは ARM で作れず「Bicep → セットアップスクリプトの 2 段デプロイ」が定型。IaC 完結を前提にした見積もりは崩れる
- Foundry Memory は同期 add ではなく LRO+debounce(既定 300 秒)。「書いた直後に読む」は成立しない前提で UX とテストを設計する

提案フロー 5 ステップと資料の対応

ステップ	やること	使う資料
1. ヒアリング	質問リストで要件採取 → 構成候補を 1～2 案に絞る	proposal/01(ヒアリングシート)
2. 実現可否チェック	候補構成の機能を GA / プレビュー確認 → リスク一覧化	features(機能一覧)
3. 概算	月額レンジを試算	proposal/02(コスト手順)
4. リスク・規制説明	顧客説明の論点を準備	proposal/03(日本規制)
5. 体制	チームの知識ギャップを確認	proposal/04(Azure 知識マップ)

- ヒアリング後のアウトプット: 構成候補 1～2 案 / プレビュー依存リスト / 廃止日程との衝突チェック / 概算月額レンジ / 規制・契約の論点リスト

詳細: [proposal/index](#) — docs/survey/proposal/README.md

Microsoft Foundry SI 勉強会 — 詳細: docs/survey/ 配下(各スライド下部のリンク参照)

ヒアリングとコスト概算の「型」

ヒアリングシート(proposal/01)

- Phase 0～7・約 30 問。**太字は地雷質問**(聞き漏らすと提案後に手戻り)
- 例: 閉域は**要件か希望か** / データを**国外に出せるか** / **ユーザーごとに見えるデータが違うか** / 引き渡し後**誰が運用するか**
- 回答 → 構成クイックマップで architecture の型に落ちる
- 閉域構成の経験則: **固定費(Firewall / PE / APIM)**だけで月額の下限が決まる — 先に固定費を積んでから変動費を載せる

コスト見積もり手順(proposal/02)

- Step 1 トークン推計(日本語 ≡ 1 文字 1 トークン。**エージェントは内部呼び出しで 2～5 倍**)
- Step 2 構成要素チェックリスト(**モデル以外が過半になる構成は珍しくない**)
- Step 3 単価取得先(**単価はドキュメントに書かない主義** = 陳腐化対策)
- Step 4 PTU 判断 / Step 5 削減レバー(Batch 50% 引き等)

詳細: [proposal/01-hearing-sheet](#) / [proposal/02-cost-estimation](#)

日本の規制対応 — 顧客定番質問に答えられる状態にしてある

- **ISMAP(政府・自治体):** 対象サービスの登録状況の確認が先決 — 案件ごとに最新を確認する設計(登録リストは変動するため文書に固定値を書かない)
- **FISC(金融):** 安全対策基準との対応整理+閉域構成(D1)が前提になりやすい
- **個人情報保護法:** 委託構成の整理+**abuse monitoring(人手レビュー)の説明**を準備 — オプトアウト申請の可否を含む
- **3省2ガイドライン(医療):** 該当時の論点を整理済み
- **位置づけ:** **G1(データ・規制)/ G2(ネットワーク)ゲートの日本ローカル具体化**。顧客からの定番質問への回答型を用意してある

詳細: [proposal/03-japan-compliance](#) — docs/survey/proposal/03-japan-compliance.md

Microsoft Foundry SI 勉強会 — 詳細: docs/survey/ 配下(各スライド下部のリンク参照)

提案書で引用できる公開事例(Microsoft 公式出典のみ)

- **Foundry / Agent Service 名指しの日本事例**: 富士通(営業支援エージェント、生産性 67% 向上)/ NTT データ(Fabric + Foundry Agent Service、市場投入 50% 短縮)/ Sky(Fabric + Foundry でデジタルワークー推進)
- **エージェント型(Azure OpenAI 名義)**: 大和証券(AI オペレーター)/ トヨタ(O-Beya)/ ソフトバンク / JR 西日本 など 5 件
- **グローバル**: Air India(1 日 4 万件処理)/ Accenture(4 か月で 17 ユースケース)/ Atomicwork(問い合わせ 65% 自動化)
- **使い方の注意**: 事例は「**同業種・同類型で公開実績がある**」ことの証明に使い、**アーキテクチャ選定の根拠には使わない**(その役割は公式リファレンス)。「Foundry 事例が少なく見える」のは主に名義変遷の問題

詳細(効果数値の正確な表現+出典 URL): [proposal/05-case-studies](#) — docs/survey/proposal/05-case-studies.md

迷ったらここから — 要件の言葉の逆引き

要件の言葉	当たりをつけるパターン
「社内文書を検索して答える」	A1 で PoC → 品質が出なければ A2
「部署によって見える文書が違う」	A2(GA 要件を満たす唯一の方式)
「担当者の承認を経て実行」	B2(MAF hosted agent)。承認待ちが数日なら B3
「複数のエージェントが協調する」	B4。ビジュアル Workflows は選ばない(2026-12-01 廃止)
「顧客向けに公開する」	C1。WAF チューニングと BOLA 対策を工数に
「複数のお客様に SaaS として提供」	C2。APIM が事実上必須
「閉域で運用する」	D1。「閉域で使えない機能一覧」から設計
「日本国内でデータ処理を完結」	Regional Standard(Japan East)。APAC Data Zone は不可
「音声で対話したい」	E1(Voice Live)。SIP 非対応に注意
「請求書を読み取って」	E2。定型は DI、非定型は Content Understanding
「月間 N 万件を処理」	E3(Batch 50% 引き)+ PTU サイジング
「既存システムに組み込む」	オーケストレーションは自前(L2 の S)。Foundry の運用機能は使えなくなる
「ロックイン回避」	Foundry はモデル供給元として使い、抽象レイヤーを自前で持つ

詳細: [architecture/index\(選定早見表\)](#) — docs/survey/architecture/README.md

この情報は腐る — 鮮度の保ち方

- 更新サイクル: **features** は月次(What's new が月次更新のため)/ **architecture** は四半期 / **proposal** は随時。**Ignite(11 月)・Build(5 月)直後は必ず更新**
- 一次情報のウォッチリスト(上から順に):
 - [What's new in Microsoft Foundry](#) — 月次の新機能・ステータス変更
 - [Feature readiness at GA](#) — GA / プレビューの最重要ページ
 - [Model retirement schedule](#) — モデルのリタイア日
- 公式ページ間でステータス表記が食い違うことがある(hosted agents / Trace Replay 等)— Feature readiness を正とする
- このスライド自体も survey の大型更新(Ignite / Build 後)に合わせて改訂する

詳細(更新手順): [features/index\(更新運用ガイドの節\)](#) — docs/survey/features/README.md

Microsoft Foundry SI 勉強会 — 詳細: docs/survey/ 配下(各スライド下部のリンク参照)

まとめ — 3 つの判断能力と、次の案件で最初にやること

	判断能力	使う道具
①	決める順序	G1～G5 を後戻りコストの大きい順に閉じる
②	当たりの付け方	要件の言葉 → A1～E6 パターン+3 軸(定義方法 / FW / 統合度)
③	見積もりの現実	「やってくれないこと 12」+廃止期限+実測ハマりどころ

次の案件で最初にやること(3 手):

1. proposal/01 のヒアリングシートで要件を採取(太字の地雷質問だけでも)
2. G1 → G5 の順にゲートを閉じ、構成候補を A1～E6 の 1～2 パターンに絞る
3. 候補構成の機能を features で GA / プレビュー確認+期限表と衝突チェック



2 層目への入口(リンク集)/ Q&A

資料	何に使う	場所
機能一覧(features)	その機能は使えるのか	docs/survey/features/html/index.html
設計ガイド(architecture)	どう組むか・パターン・運用	docs/survey/architecture/html/index.html
提案実務(proposal)	ヒアリング・コスト・規制・事例	docs/survey/proposal/html/index.html
技術選定ガイド	実装で実証した判断基準	docs/tech-selection-guide.md
学習計画(3 軸の原典)	選定の全体像	docs/learning-plan.md
移植ラボ(実装例 14 本)	動くコード・テスト・Bicep	labs/maf-ports/README.md

- HTML はリポジトリを clone してブラウザで開くだけ(ビルド済みでコミットされている)
- 以降は付録(パターン完全版 / やってこないこと全 12 項 / 期限全体表 / Copilot Studio 境界)

[features](#) / [architecture](#) / [proposal](#) / [tech-selection-guide](#) / [learning-plan](#) / [labs/maf-ports](#)

付録 A1: ユースケース別パターン完全版(A1～E6)

詳細: [architecture/index](#) — docs/survey/architecture/README.md

ID	パターン	オーケストレーション	RAG / ナレッジ	主な決め手
A1	部門内 FAQ チャット	Prompt agent	File Search	速度優先。権限制御なし
A2	全社ナレッジ検索(本番)	Prompt / Hosted agent	AI Search 自前索引	ユーザーごとに見える文書が違う
A3	既存 AI Search 資産の活用	Prompt agent	AI Search ツール直結	索引設計を自分で持ち続けたい
A4	M365 / SharePoint 主データ源	Prompt agent	SharePoint ツール(OBO)	権限透過。M365 Copilot ライセンス前提
A5	複数ソース横断・高精度	任意(MCP 経由)	Foundry IQ	複数エージェントでナレッジ共有
B1	単一エージェント+基幹 API	Prompt agent + Toolbox	補助的	参照系中心
B2	承認付き業務自動化(HITL)	MAF hosted agent	調査工程で使用	「担当者が承認してから実行」
B3	長時間・確実な再開	MAF + Durable Extension + DTS	任意	数時間～数日停止して再開
B4	マルチエージェント(専門分化)	MAF workflows / A2A	領域別	領域ごとに権限を分けたい
B5	業務フローエンジン主導	Logic Apps / Copilot Studio	任意	業務部門がビジュアルで保守
C1	一般顧客向けチャット	任意	任意	不特定多数(公開 + WAF + APIM)
C2	マルチテナント SaaS	Hosted agent(プロトコル 2.0.0)	テナント別索引	複数顧客に販売(APIM 必須)
C3	大規模・複数部門への払い出し	任意	任意	部門別按分・キャパシティ(APIM 必須)
D1	規制業種・閉域	Hosted agent or 自前	AI Search 自前索引一択	BYO VNet。閉域・監査・データ主権
D2	ソブリン(Azure Government)	Prompt agent 対応	File Search / AI Search	hosted agent・MCP・A2A 非対応
D3	エッジ・オンプレ	Foundry 非依存	自前	Foundry Local / Azure Local 版 / 切断コンテナ
E1	音声エージェント	Voice Live API	任意	リアルタイム音声対話(SIP 非対応)
E2	文書処理・IDP	非同期パイプライン	DI / Content Understanding	帳票・契約書の構造化抽出
E3	大量バッチ処理	ジョブ実行基盤	不要	Batch で 50% 割引
E4	マルチモーダル生成	非同期ジョブ	不要	画像・動画生成(閉域不可)
E5	M365 / Teams 連携	Prompt / Hosted agent	Work IQ 等	業務ツール内で使わせる
E6	ファインチューニング運用	MLOps パイプライン	併用推奨	挙動・文体をモデル側で変える

付録 A2: Foundry がやってくれないこと(全 12 項)

#	やってくれないこと	誰が埋めるか
1	リージョン間の自動フェイルオーバー・DR(復旧は再構築)	アプリ層ルーティング + Cosmos 継続バックアップ + 再構築パイプライン
2	会話へのユーザー単位の認可(BOLA)	アプリ側で所有権をリクエストごとに検証
3	エージェントの blue-green / canary	APIM 等のルーティング層
4	モデルデプロイのラウンドロビン・サーキットブレーカー	APIM のバックエンドプール + circuit breaker
5	部門・テナント別のトークン計測と課金按分	APIM llm-emit-token-metric
6	コストのハードリミット	予算アラート + 自作の自動化
7	プロジェクト内のエージェント単位のアクセス制御	アプリの認証認可層 / hosted agent の Entra Agent ID
8	max_output_tokens / truncation によるトークン制御	自前オーケストレーション
9	閉域での Traces / Memory / File Search / Work IQ / 画像生成 等	自前実装または機能除外
10	Claude モデルへのコンテンツフィルター	APIM llm-content-safety かアプリ層で Content Safety
11	音声モデルへのガードレール	テキスト化後の経路で Content Safety
12	capabilityHost の更新(変更は削除・再作成)	IaC を「作り直し前提」で設計

- 加えてコンテンツフィルターはフェイルオープン — 規制業種は finish_reason / content_filter_results の検証を必須実装に

詳細: [architecture/index\(全案件共通の前提の節\)](#) — docs/survey/architecture/README.md

付録 A3: 重要期限の全体表(features 側)

詳細: [features/index](#) — docs/survey/features/README.md

期限	対象	影響・移行先
2026-08-20	Hosted agents 初期レビュー基盤	サポート終了。新基盤へ再デプロイ必須
2026-08-26	Assistants API(Azure OpenAI)	廃止。Responses API(Agents v2)へ
2026-08-26	<code>azure-ai-inference</code> SDK	廃止(beta のまま GA せず終了)。OpenAI SDK + v1 API へ
2026-08-31	NTT Data <code>tsuzumi-7b</code> (Legacy)	廃止。後継 <code>tsuzumi2</code> へ。 日本語特化モデル案件で効く
2026-10-01 前後	<code>gpt-4o</code> / <code>o1</code> / <code>o3</code> / <code>o4-mini</code> 等の旧モデル群	リタイア
2026-10-14	<code>gpt-4.1-nano</code>	リタイア(<code>gpt-4.1</code> / <code>mini</code> より約半年早い。混同しない)
2026-10-14	Azure OpenAI On Your Data	廃止。Foundry Agent Service + Foundry IQ へ
2026-12-01	ビジュアル Workflows	廃止。MAF / Logic Apps / A2A へ
2027-03-31	Agents (classic)(v1、Threads / Runs)	廃止。Agents v2 へ(状態データは自動移行されない)
2027-04-20	prompt flow	廃止。新規開発に非推奨。MAF へ
2028-09-25	Azure AI Vision Image Analysis 4.0 / 3.2	廃止。DI / Content Understanding / Foundry Models へ
日付未公表	Agent Applications / コンテナプロトコル 1.0.0	廃止予告済み(1.0.0 は 2026-07-31 からブロック開始と公表)
予告 15 日のみ	Fireworks 系モデル(<code>FW-*</code>)	標準 60 日でなく 15 日前通知 。本番の必須経路に置かない

付録 A4: Copilot Studio との境界線(一次情報で引ける)

- Copilot Studio → Foundry(プロコード)への乗り換えシグナル 3 つ(公式ドキュメントで裏づけ):
 - 30～40 アクション超でオーケストレーターの実行精度が落ちる(公式明記)
 - 多段のエージェント階層が組めない(connected agents を持つエージェントは他の connected agent になれない)
 - 決定的ワークフローが業務クリティカル — CAF が「Foundry / MAF の workflows を使え」と実装先を名指し
- 選定の決め手は機能でなく「誰が作り・誰が保守し・どこまで制御が要るか」(CAF デシジョンツリー)
- 両者は排他ではない — 入口・M365 チャネル・業務部門の保守は Copilot Studio、複雑な処理は Foundry hosted agent(connected agent として呼ぶ)が公式推奨の分業構成。**SI の受託範囲を「Copilot Studio で簡単に作れないエージェントの開発」とする契約の切り方が公式構成と一致(ただし接続はレビュー)**

詳細: [architecture/11-decision-frameworks](#) — docs/survey/architecture/11-decision-frameworks.md