

Microsoft Foundry を SI で使う

技術選定とアーキテクチャ判断の基準

2026-08 / 課内共有

本リポジトリの調査(survey)+実装検証(labs)の入口となる資料



今日のゴール

持ち帰るのは機能の知識ではなく、3つの「判断能力」

① 決める順序

後戻りコストの大きい順に
5つのゲート(G1～G5)で閉じる

② 当たりの付け方

要件の言葉を
22パターン+選定3軸に当てて1～2案
に絞る

③ 見積もりの現実

「やってくれないこと」と廃止期限を工数・リ
スクに乗せる

- 全機能の暗記は不要 — 「どこを見れば載っているか」が分かれば提案は書ける
- 略語は初出でスペルアウトし、巻末の付録 A7 に用語集を用意した

2 層目の全体像: [survey/README.md](#) — docs/survey/README.md

資料の全体像(2 層構成)

この資料は入口(1 層目) — 詳細は 2 層目の調査資産に降りられる

このスライド(1 層目)

判断の骨組みだけを 45 分で



features

その機能は**使えるのか**
GA(一般提供)/ プレビュー
を約 200 機能・出典つき
で。月次更新

architecture

どう組むか
公式リファレンス+ユースケ
ース別パターン+運用・移
行。四半期更新

proposal

どう提案するか
ヒアリング・コスト手順・日
本規制・公開事例

labs+選定ガイド

実装で**実証**できたこと
動くコード 14 本+テスト
約 470 件

- 各スライドの下部に、該当する 2 層目へのリンクとリポジトリ内パスを常設してある
- 「公式ドキュメント調査(survey)」と「実装検証(labs)」は**出典を分離** — 提案書で根拠を二本立てにできる

詳細: [features](#) / [architecture](#) / [proposal](#) / [tech-selection-guide](#) — docs/survey/README.md

前提: Ignite 2025 の改称

検索で出てくる情報の大半は旧名義 — 新旧対応表を頭に入れて読む

観点	旧	現行
ブランド	Azure AI Studio / Azure AI Foundry	Microsoft Foundry
付帯 AI サービス	Azure AI Services	Foundry Tools
エージェント API	Assistants API(Threads / Runs)	Responses API(Agents v2)
リソースモデル	Hub + Azure OpenAI + AI Services	Foundry リソース(単一)
SDK	<code>azure-ai-inference</code> 等 複数	<code>azure-ai-projects</code> 2.x + <code>openai</code>
ドキュメント	<code>/azure/ai-foundry/</code>	<code>/azure/foundry/</code> (新)+ <code>/azure/foundry-classic/</code> (旧)

- 対応表なしで検索すると、**廃止済み API** の記事で設計してしまう(メンバーの過去調査も旧名義の可能性)

詳細: [features/index\(前提知識の節\)](#) — docs/survey/features/README.md

機能の全体像(8 カテゴリ)

全機能は 8 カテゴリの「地図」に整理済み — 位置だけ覚えれば引ける

01 プラットフォーム基盤

リソース / プロジェクト / アクセス制御 / ネットワーク / IaC(コード化したインフラ)

02 モデル

カタログ(OpenAI / Claude / Grok 等) / デプロイタイプ / Model router / Foundry Local

03 Agent Service

Agents v2(Responses API) / prompt・hosted エージェント / Memory / Routines

04 ツール・ナレッジ

File Search / AI Search / Web search / MCP / Foundry IQ

05 観測・評価

トレーシング / 評価器 / クラウド評価 / AI Red Teaming

06 ガードレール

コンテンツフィルター / Prompt Shields / 根拠性検出 / 個人情報検出

07 Foundry Tools

Speech(Voice Live) / Document Intelligence / Content Understanding

08 開発者サーフェス

v1 API / SDK / CLI / Bicep / Microsoft Agent Framework / LangGraph 統合

- 各カテゴリとも GA / プレビュー+操作手段(ポータル / CLI / SDK / REST)を全行出典つきで整理済み

詳細: [features/index](#) — docs/survey/features/01~08-*.md

GA / プレビューの現実

「GA」を鵜呑みにしない — 選定に効く 4 つの現実

① GA / プレビューは機能単位で混在

新ポータル自体は GA でも中身はバラバラ。体系的な一覧は公式
Feature readiness at GA が唯一 — 提案前に必ず引く

② GA でも足元の基盤が動いている

hosted エージェントは 2026-08-20 に初期基盤終了(再デプロイ必須)、ビジュアル Workflows は 2026-12-01 廃止

③ CLI は一級市民ではない

専用の `az foundry` は存在しない。多くの機能が「ポータル+SDK / REST のみ」— 自動化の見積もりに直接効く

④ Claude(Anthropic)は独自制約つき


モデルとしては GA。ただし Anthropic SDK+Marketplace 課金 +Foundry 組み込みコンテンツフィルター非適用

詳細: [features/index\(ハイライトの節\)](#) — [docs/survey/features/README.md](#)

公式-C Landing Zones 版 — 全社共通基盤(hub-spoke)向け。実装コードは削除済み・プレビュー

- それ以外の公式ページは検証レベルが下がる — 提案での引用時は区別する

Microsoft Foundry SI - 機能、アーキ選定 SI 観点の共有 — 詳細: docs/survey/ 配下(各スライド下部のリンク参照)



→ data / control ↔ telemetry (IoT) auth billing note Source: AAC baseline-microsoft-foundry-chat -> docs/survey/architecture/01

Web search tool calls api.bing.microsoft.com internally and BYPASSSES the egress subnet -> validate every tool against egress policy (stated in the article).

No built-in DR: no state replication / backup / PITR in Agent Service -> recovery = rebuild (mitigate: Cosmos PITR, agent-as-code, user-assigned ML delete locks).

Top costs: Cosmos DB / AI Service / JDDoS Protection, then UI compute + App Gateway. Agents call tools non-deterministically -> external API cost can spike.

Auth: user -> Entra ID / API Service & prompt agents -> shared project managed identity (split projects per access pattern) / per-user conversation auth = app responsibility (BOLA)

判断①: 5 つのゲート

構成の決定は「後戻りコストの大きい順」— 5 つのゲートを上から閉じる

後戻りコスト 大 ▲

G1 データ・規制	そのデータを、どこで、誰に処理させてよいか	モデル・デプロイタイプ・外部ツール可否が決まる
G2 ネットワーク	閉域か、パブリックか	使える Foundry 機能の一覧が決まる(後付け不可)
G3 制御	明示的な分岐・承認・再開が要るか	ポータル完結か、コードファーストかが決まる
G4 統合	既存システムとの主従はどちらか	プラットフォームとして使うか、部品として使うか
G5 ライフサイクル	いつまで、誰が保守するか	プレビュー可否・IaC の作り込み度が決まる

後戻りコスト 小 ▼

- 機能比較表から入ると G1 / G2 の手戻りで壊れる — 上から順に閉じるのがこのガイドの背骨

詳細: [architecture/03-decision-guide](#) — docs/survey/architecture/03-decision-guide.md

G1 データ・G2 ネットワーク

G1・G2 は後付けできない — 最初のヒアリングで確定させる 4 点

閉域構成は作成後に変更できない

BYO VNet 注入(自前の仮想ネットワークへの組み込み)はリソース作成時のみ。後から閉域要件が出ると作り直し

閉域では使えない機能が多い

File Search / トレース / Memory / 画像生成など。「閉域で使えない機能の一覧」から設計を始める

「国内処理の完結」は選択肢が 1 つ

Regional Standard(Japan East)のみ。APAC Data Zone は日豪韓星印で処理されうるため不可

Web 検索はコンプライアンス境界の外

Grounding with Bing は DPA(Microsoft のデータ保護補遺)対象外・別課金。規制業種では原則不可として扱う

詳細: [architecture/07-usecase-regulated-edge](#) — docs/survey/architecture/07-usecase-regulated-edge.md

G3～G5 と机上決定

事例がなくても構成は机上で決められる — 公式が「試作省略可」と明言

G3 制御

分岐・ループ・承認・再開の明示制御が要
るならコードファースト

G4 統合

既存システムが主なら「モデルとツールだけ
借りる」構成(Responses API のみ利用)

G5 ライフサイクル

顧客内製・非開発者運用ならポータル中
心。プレビュー許容度もここで確定

CAF(Cloud Adoption Framework: Microsoft のクラウド導入方法論)の明言 — 「Skip prototyping: Yes(複数試作の比較は不要)」「クリティカルな業務ロジックには決定的ワークフローを強制せよ(Foundry / MAF=Microsoft Agent Framework)」

- 実測が要るのは**品質とコストの実額だけ** — そこは評価ハーネスで回帰可能にする

詳細: [architecture/11-decision-frameworks](#) — docs/survey/architecture/11-decision-frameworks.md

判断②: パターン全体マップ

要件の言葉をまず「5 つの家族・22 パターン」に当てる

A 社内ナレッジ検索・RAG(A1～A5)

RAG(検索拡張生成: 文書を検索して根拠つきで回答)。SI 案件で最多。部門 FAQ / 全社検索 / M365 連携など

B 業務自動化・マルチエージェント(B1～B5)

基幹 API 連携 / 承認付き自動化 / 長時間実行 / 複数エージェント協調

C 顧客向け公開(C1～C3)

不特定多数への公開 / マルチテナント SaaS / 大規模払い出し

D 規制業種・閉域・エッジ(D1～D3)

金融・公共の閉域 / 政府クラウド / オンプレ・エッジ実行

E 特化型(E1～E6)

音声 / 文書処理 / 大量バッチ / 画像・動画生成 / M365 連携 / 追加学習

使い方

要件を聞いたらこの 22 パターンのどれかに落とす。完全版の一覧表は付録 A1、要件の言葉からの逆引きは付録 A6


詳細: [architecture/index](#) — docs/survey/architecture/README.md

A: 社内ナレッジ検索・RAG

A1 で小さく始めて、権限制御が要るなら A2 に上げるのが本線

A1 / A3 / A4: Prompt agent + managed knowledge — same shape, three knowledge choices

The smallest managed configs. Escalate to A2 (own index) when per-user visibility, metadata filters, xlsx, or closed network enter the requirements.




→ data / control → telemetry (Otel) auth billing note Source: docs/survey/architecture/04 A1, A3, A4
 A1 dead-ends (check first): no doc-level ACL / no metadata filter / no xlsx-csv / not available in closed network -> any of these means A2.
 A3: agent evaluators (groundedness, tool_call_accuracy...) are officially unusable with the AI Search tool -> CI evals need A5 (MCP) or your own harness.
 A1 cost = tokens + vector storage GB/day, A4 needs M365 Copilot license (or Retrieval API pay-as-you-go for devs AND end users; not usable from Teams-published agents).
 Auth: user -> Entra ID / A3 tool -> project managed identity (key auth impossible in private VNet) / A4 -> OBO only: batch and autonomous agents cannot use it

A1: File Search 最小構成 — PoC 向け。権限制御なし・設定固定

A2: Company-wide knowledge search — own AI Search index (production standard)

Per-user document visibility (security filter / ACL). You own chunking, embeddings, metadata; integrated vectorization + semantic ranker stay managed.



→ data / control → telemetry (Otel) auth billing note Source: docs/survey/architecture/04 A2 (closed-network variant: ch.07)
 Chunk strategy is a semi-permanent choice (official wording) - re-chunking means full re-index. Decide chunk size / overlap / language analyzer up front.
 Semantic ranker reranks TOP-50 only (L1 recall failures cannot be rescued); vector index quota per partition is a hard limit (Basic 5GB / S1 35GB / S2 150GB / S3 300GB).
 Doc-level ACL: security filter (GA, group IDs in index) or query-source-authorization (preview) - see ch.04 for the 4 options.
 Auth: user -> Entra ID / agent -> AI Search via managed identity + PE / per-user visibility enforced in the query, never in the prompt

A2: AI Search 自前索引 — 本番の標準形。ユーザーごとに見える文書を絞れる

- 「部署によって見える文書が違う」と聞いたら **A2 一択**(GA 要件を満たす唯一の方式)
- PoC 段階で難しい文書 20~30 件の検索品質を測ってから方式を確定する

詳細: [architecture/04-usecase-chat-rag](#) — docs/survey/architecture/04-usecase-chat-rag.md

A: ナレッジの持たせ方 5 分岐

「データの場所と権限」で決まる — 上から順に聞けば 1 つに落ちる

ユーザーごとに見える文書が違う?

はい → **A2** AI Search 自前索引(本番の標準形)

M365 / SharePoint が主データ源?

はい → **A4** SharePoint ツール(権限透過。ライセンス前提・プレビュー)

既存の AI Search 索引資産がある?

はい → **A3** AI Search ツール直結(索引設計は自前で持ち続ける)

複数ソースを複数エージェントで共有?

はい → **A5** Foundry IQ(agentic retrieval。一部 GA)

どれも無い(小規模・静的データ)

→ **A1** File Search 最小構成

⚠ **Azure OpenAI On Your Data は 2026-10-14 廃止** — 「モデルが直接データを読む」構成の既存提案書は要更新(移行先: Agent Service+Foundry IQ)

詳細: [architecture/04-usecase-chat-rag](#) — docs/survey/architecture/04-usecase-chat-rag.md

B: 承認付き業務自動化

本線は **B2** —「担当者が承認してから実行」を
MAF で作る

図: B2 承認付き業務自動化(MAF hosted エージェント)

- HITL(Human-in-the-Loop)= 処理の途中に人の承認を挟む構成
- 参照系(読み取りだけ)なら B1 のツール呼び出し構成で足りる


詳細: [architecture/05-usecase-agent-automation](#) —

[docs/survey/architecture/05-usecase-agent-automation.md](#)

Microsoft Foundry SI - 機能、アーキ選定 SI 観点の共有 — 詳細: docs/survey/ 配下(各スライド下部のリンク参照)

B2: Approval-gated automation (HITL) — MAF hosted agent

Agent investigates -> proposes action -> human approves -> execute -> audit. Prompt agents cannot express this: branch / wait / resume => code-first.




→ data / control - - - telemetry (OTel) auth billing note Source: docs/survey/architecture/05 B2
Idle 15 min = compute deprovision (state kept) / 30 days inactive = permanent delete. Multi-day approvals -> B3 (Durable Extension + DTS).
Tracing is NOT the business audit log: 90-day portal window, traces may carry prompts/PII, no VNet support -> keep who/when/what-approved in your own store (MAF middleware).
Billing = CPU + memory of all active sessions: oversizing multiplies by concurrency. MAF Graph API is the supported surface (Functional API is experimental).
Auth: approver -> business UI (Entra ID) / hosted agent -> Entra Agent ID (per-agent, not shared) / LOB tools -> APIM: decide OBO vs app-only per tool

B: 長時間実行・複数エージェント

承認待ちが日単位なら B3、権限を分けたいなら B4 に拡張する

B3: Long-running processes with guaranteed resume — MAF + Durable Extension

Multi-day approvals, waiting on external batches, resume-from-failed-step. Check this BEFORE concluding 'MAF can't do long-running, switch to LangGraph'.




→ data / control - - - telemetry (OTel) auth billing note Source: docs/survey/architecture/05 B3
Backend: DTS recommended (highest perf, managed, built-in observability dashboard). Reliable streaming across distributed hosts needs a separate Redis-class broker.
No official pattern for DTS INSIDE a Foundry hosted agent was found -> host on Functions or your own compute when Durable is required.
If AI is just one step and approvals/waits dominate, Logic Apps / Durable Functions alone may be the better main engine (-> B5).
Auth: approver via your app (Entra ID) / Functions -> DTS via managed identity

B3: 長時間・確実な再開 — Durable Extension+DTS(Durable Task Scheduler)
で数時間～数日の停止・再開

B4: Multi-agent with domain specialization — MAF workflow + hosted agents

Only when per-domain prompts / knowledge / PERMISSIONS must differ, or parallel research pays. Single agent + tools is enough for most cases (-> ch.11).



→ data / control - - - telemetry (OTel) auth billing note Source: docs/survey/architecture/05 B4 (pattern selection: ch.11)
Portal visual Workflows retire 2026-12-01 -> MAF (code, recommended) / Logic Apps (visual) / A2A (simple delegation). Export the YAML before the designer disappears.
Prompt agents SHARE one identity per project -> per-agent permissions & audit need hosted agents (each gets its own Entra Agent ID) or separate projects.
Security trimming must be implemented in EVERY agent (official). Anti-patterns: agents without real specialization, shared mutable state between parallel agents.
Auth: per-agent Entra Agent ID = least privilege per domain / A2A callers need Foundry Agent Consumer role, key auth impossible

B4: マルチエージェント(専門分化) — 領域ごとに権限・責務を分離

- B3 は「承認者が数日戻らない」前提の設計。プロセス再起動をまたいで**確実に再開**できる
- B4 に進む前に**まず単一エージェントで始める**(協調の型は §4 で扱う)

B: ビジュアル Workflows 廃止

2026-12-01 に廃止 — ポータルでマルチエージェントは組まない

図: B5 業務フローエンジン主導(Logic Apps / Copilot Studio)


- 廃止はビジュアル Workflows のみ — エージェント作成・公開・Connected Agents は残る
- 移行先は MAF(推奨)/ Logic Apps / A2A(エージェント間連携プロトコル)
- ビジュアル保守を続けたいなら B5 に倒す(境界線は付録 A4)

詳細: [architecture/05-usecase-agent-automation](#) —

[docs/survey/architecture/05-usecase-agent-automation.md](#)

B5: Business-flow engine in charge — Logic Apps / Copilot Studio + Foundry as a component

Approvals, notifications and SaaS integration are the main flow; AI handles part of the judgement. Business departments maintain the flow themselves.



C: 顧客向け公開・SaaS

主戦場は境界防御 — 会話の認可を Foundry はやってくれない


図: C2 マルチテナント SaaS(APIM 前段の標準構成)

- BOLA 対策はアプリ側の必須実装(BOLA = Broken Object Level Authorization: 他人の会話 ID を指定すると読めてしまう認可不備)
- 境界は WAF(Web Application Firewall)+APIM(Azure API Management)。課金按分も APIM で自前
- クォータはデプロイ単位 — 分割で暴走を隔離

詳細: [architecture/06-usecase-customer-facing](#) — docs/survey/architecture/06-usecase-customer-facing.md

C2: Multi-tenant SaaS — shared by default, dedicated by justification

Official default: shared model deployment. Dedicated per-tenant deployments only for quota/chargeback, filter policies, model lifecycle, fine-tuning, or residency.





→ data / control --> telemetry (OTel) auth billing note Source: docs/survey/architecture/06 C2 (C1 = single-tenant subset / C3 = APIM capacity view)

Official pitfalls: shared instances give NO per-deployment security isolation; noisy neighbor; NEVER share an instance that hosts fine-tuned models.
Responses API weakens tenant isolation (official): scope response IDs to tenants in YOUR store; built-in tools (Code Interpreter / MCP) need per-tenant containers/configs.
Chargeback is app-side by design: track per-tenant tokens in the app (APIM metric eases this). Limits: 32 deployments/resource, 100 Foundry resources/region/sub.
Auth: never let LLM output carry tenant identity (official: don't rely on the model to propagate tenant info); per-user conversation authz stays app responsibility

D: 規制業種・閉域・エッジ

閉域は「使えない機能の一覧」から設計する — 月額の下限は固定費で決まる



D1: 規制業種・閉域 — BYO VNet+Private Endpoint(閉域接続の受け口)群

D3: エッジ・オンプレ — Foundry Local / Azure Local / 切断コンテナ

- 固定費を先に積む(Firewall / Private Endpoint / APIM)— トークン代より固定費が支配的
- D2(政府クラウド)は hosted エージェント・MCP(ツール接続規格)・A2A が非対応

詳細: [architecture/07-usecase-regulated-edge](https://docs.microsoft.com/ja-jp/survey/architecture/07-usecase-regulated-edge) — docs/survey/architecture/07-usecase-regulated-edge.md

E: チャット以外の 6 類型

「索引」と「落とし穴」だけ持ち帰る — 各類型の構成図は 2 層目にある

ID	類型	使うもの	落とし穴
E1	音声エージェント	Voice Live API	SIP(電話網接続の標準プロトコル)非対応・ガードレール非適用
E2	文書処理(IDP)	Document Intelligence(定型帳票)/ Content Understanding(非定型)	後者はページ課金・BYO モデル接続必須
E3	大量バッチ	Batch デプロイ	50% 引きだが 24 時間ターゲット・SLA なし
E4	画像・動画生成	非同期ジョブ	閉域不可
E5	M365 / Teams 連携	公開フロー(GA)	Bot Service が別途必要
E6	ファインチューニング	MLOps パイプライン	知識の追加は RAG、挙動・文体の変更が FT。デプロイは作り直し前提

- IDP = Intelligent Document Processing(帳票・契約書の構造化抽出)。FT = Fine-tuning(追加学習)

詳細: [architecture/08-usecase-specialized](#) — docs/survey/architecture/08-usecase-specialized.md

Microsoft Foundry SI - 機能、アーキ選定 SI 観点の共有 — 詳細: docs/survey/ 配下(各スライド下部のリンク参照)

判断②: フレームワーク選定の 3 軸

「ポータル vs MAF vs LangGraph」と一列に並べない — 独立した 3 つの軸で決める

軸A 定義方法

Prompt エージェント — 構成のみ・フルマネージド実行

Hosted エージェント — 自前コードをデプロイ

軸B フレームワーク

MAF

LangGraph

OpenAI Agents SDK

自前コード

軸C 統合度

フル統合

Responses API のみ — モデルとツールだけ借りる

Foundry 非依存

- Hosted エージェントは **MAF 専用ではない** — LangGraph 製エージェントを Foundry にホストする構成も公式サポートの正規ルート
- 「Foundry を使うか」と「MAF を使うか」は**独立した判断**。既存システム組み込み型の SI 案件では軸C の「Responses API のみ」が重要

詳細: docs/learning-plan.md §2(技術選定の全体像) — [learning-plan.md](#)

レイヤー別「任せる / 作る」

16 のレイヤーごとに「Foundry に任せる / 自前で作る」を選ぶ — 全体表は付録 A5

- 凡例: **M** フルマネージド(Foundry 機能)/ **H** ハイブリッド / **S** 自前実装
- L2 オーケストレーション** — 迷ったら Hosted エージェント(MAF / LangGraph)
- L4 長期記憶** — Foundry Memory はプレビュー。本番は自前サマライズ+ベクトル検索
- L5 ナレッジ / RAG** — 本番は AI Search 自前索引(A2 と同じ判断)
- L11 ゲートウェイ** — 按分・レート制御が要るなら APIM(AI ゲートウェイ)
- L16 IaC・CI/CD** — データプレーンは Bicep の外(§5 で詳述)

M	H	S
M	H	S
M	H	S
M	H	S
M	H	S
M	H	S

- 「迷ったら」列は**既定値**であって**正解**ではない — 各レイヤーの全選択肢と根拠は 2 層目に整理済み

詳細(16 レイヤー全体): [architecture/02-building-blocks](#) / 付録 A5 — docs/survey/architecture/02-building-blocks.md

マルチエージェント協調の型

協調は 2 つの軸で 3 つの型に割り切れる — そもそも単一で始める

制御の流れをコードが決める(順序・分岐が事前に確定)

→

グラフ型 — MAF Workflow。直列・並列・分岐・ループ

LLM が相手を選び、応答が戻る

→

相談型(agent-as-tool) — エージェントをツールとして呼ぶ

LLM が相手を選び、制御が移る

→

担当交代(handoff) — サポートのエスカレーション等

- **そもそも単一エージェントで始める** — CAF は最初からマルチにしてよい条件を 3 つに限定。Anthropic の公表値ではマルチはトークン消費 3～10 倍
- 実測: 元アプリの「handoff」の多くは実は**固定シーケンス** — グラフ化で失うものではなく、型・テスト・可視化を得る

詳細: docs/tech-selection-guide.md §1-1 / [architecture/11\(公式 5 パターンとの対照\)](#)

フレームワーク移行コスト

他フレームワークからの書き換えは実測済み — 移行は思ったより軽い

元フレームワーク → MAF	書き換えの実態(14 本の移植から)
LangGraph(StateGraph)	ノード→Executor、条件エッジ→switch-case。型なし共有 dict が型付きメッセージになる
OpenAI Agents SDK	handoff 1 行 → 構造化出力+switch-case の数十行。ただしテスト可能になる
AG2 旧 Swarm	長寿命エージェントの「必要悪」が、ステートレスな純関数に縮退
LangChain ルーター	三段カスケード約 150 行が Foundry IQ の宣言に消滅(可観測性・単体テストは失う)
ADK + FastAPI 常時稼働	hosted エージェント化で変わるのは周辺 3 点のみ。cron 配管は Routines へ

- 共通パターン: 書き換えで元コードの欠陥が見つかる — 型付きグラフへの移植自体がコードレビューとして機能する

詳細(全 14 行+検証元): docs/tech-selection-guide.md §1-3 — [tech-selection-guide.md](#)

実証済みコードの対応表

「事例がない」には動くコードで答える — 8 つの型 × 約 470 テスト

作りたいもの	実証済みの型	検証コード(labs)
直列パイプライン	Executor+エッジ、進捗イベント	trend-analysis
並列実行+合流	fan-out / fan-in エッジ	mixture-of-agents
ルーティング / トリアージ	構造化出力+switch-case	research-handoff
自己補正 RAG	採点→分岐→書き換えのグラフ+AI Search	corrective-rag
評価駆動の品質ループ	サイクリックグラフ+クラウド評価	critique-loop
常時稼働+スケジュール	hosted エージェント+Routines	hn-briefing-hosted
音声エージェント	Voice Live(3 層分離)	claim-voice-live
ガバナンス / 監査	middleware 3 種+ハッシュ連鎖監査	governed-agent

- 顧客事例ではないが、動くコード+テスト+IaC 一式が型ごとにある — 実現可否確認と工数見積もりの根拠に使える
- Foundry に載せる最初の動機は観測性 — トレース配線は実質 2 行

Microsoft Foundry SI - 機能、アーキ選定 SI 観点の共有 — 詳細: docs/survey/ 配下(各スライド下部のリンク参照)

判断③: やってこないこと

「Foundry がやってこないこと」を先に顧客と合意する — 頻出 5 つ

① 災害復旧・フェイルオーバー

リージョン間の自動切替なし。**復旧は再構築** — アプリ層ルーティング+再構築パイプラインで埋める

② 会話のユーザー単位認可

BOLA 対策なし — アプリ側で所有権をリクエストごとに検証

③ blue-green / canary 配備

エージェントの段階的リリース機能なし — APIM 等のルーティング層で

④ 部門・テナント別の課金按分

トークン計測は APIM の `llm-emit-token-metric` で自前実装

⑤ コストのハードリミット

公式明記: **機能が存在しない** — 予算アラート+自作の自動化で

⚠ フィルターはフェイルオープン

コンテンツフィルターが利用不能のとき**遮断せず素通し**で HTTP 200 を返す — 規制業種は応答検証を必須実装に

- 全 12 項目は**付録 A2** — 提案書の**除外事項・前提条件欄**にそのまま転記できる形にしてある

詳細: [architecture/index\(全案件共通の前提の節\)](#) — docs/survey/architecture/README.md

重要期限 2026–2027

提案書には賞味期限がある — 直近 4 つの廃止日は暗記する

●	●	●	●	●	●
2026-08-20	2026-08-26	2026-10-14	2026-12-01	2027-03-31	2027-04-20
Hosted エージェント旧基盤	Assistants API	On Your Data	ビジュアル Workflows	Agents (classic)	prompt flow
自動移行なし。再デプロイ必須	Threads / Runs 前提のアプリは全面改修	RAG の既存提案書は要更新	ポータルでのマルチエージェント構成が消える	状態データは移行されない	新規開発に非推奨・MAF へ

- PoC → 本番のスケジュールと**期限の衝突チェック**を提案フローに組み込む(期間内に廃止が来るなら最初から後継 API で作る)
- モデル自体のリタイア(gpt-4o 等 2026-10 前後)も含めた**全体表は付録 A3**

詳細: [architecture/10-migration-antipatterns](#) / [features/index](#)(期限表)



提案のアンチパターン

踏みやすい 11 個のうち代表 3 つ — 言う前・見積もる前に確認する

「ポータルで全部できます」

ポータル完結は「単一エージェント+カタログツール+公開」まで。分岐・承認・ローカルテストは入らない

対処: ポータル完結の範囲とコードが要る範囲の線引き表を提案に添える

File Search で品質が出ないまま押し切る

チャンク・埋め込み設定は固定で、日本語長文・表主体の文書に合わないことがある

対処: PoC で難しい文書 20～30 件を測り、駄目なら早期に AI Search へ

az CLI で自動化できる前提の見積もり

専用の `az foundry` は存在せず、多くの機能はポータル+SDK / REST のみ

対処: 自動化は Bicep / Terraform(基盤)+SDK / REST(データ操作)前提で工数を積む

詳細(全 11 個): [architecture/10-migration-antipatterns](#) — docs/survey/architecture/10-migration-antipatterns.md

実装のハマりどころ

「半日溶けるポイント」は先に知っておく — 実測 3 点

権限の反映が遅く・不均一

RBAC(ロールベースアクセス制御)の伝播は 5〜15 分。さらに Bicep 作成のプロジェクトは実行 ID にモデル操作権限が**自動付与されない**(ポータル作成は付く)— 401 エラーの切り分けで半日溶ける

laC だけでは完結しない

AI Search の索引や Memory ストアは Bicep / ARM で作れない。「**Bicep → セットアップスクリプトの 2 段デプロイ**」が定型 — laC 完結前提の見積もりは崩れる

Memory は「書いた直後に読めない」

Foundry Memory は同期書き込みではなく**非同期処理+既定 300 秒の遅延**(LRO+debounce)— UX とテストはその前提で設計する

詳細(全 13 点+検証元): [docs/tech-selection-guide.md §2\(実装ナレッジ集\)](#) — [tech-selection-guide.md](#)

提案フロー

5 ステップの型に資料を対応済み — 明日から使える



- ヒアリング後のアウトプット: 構成候補 1～2 案 / プレビュー依存リスト / 廃止日程との衝突チェック / 概算月額レンジ / 規制・契約の論点リスト

詳細: [proposal/index](#) — docs/survey/proposal/README.md

ヒアリングとコスト概算

ヒアリングは「地雷質問」から、コストは「固定費」から積む

ヒアリングシート(proposal/01)

Phase 0～7・約 30 問。太字は**地雷質問**(聞き漏らすと提案後に手戻り)

例: 閉域は要件か希望か / データを国外に出せるか / ユーザーごとに見えるデータが違うか / 引き渡し後は誰が運用するか

コスト見積もり手順(proposal/02)

トークン推計(日本語 ≡ 1 文字 1 トークン。エージェントは内部呼び出しで 2～5 倍) → 構成要素チェック → 単価取得 → PTU(スループット予約)判断 → 削減レバー

単価はドキュメントに書かない主義(陳腐化対策)。モデル以外が過半になる構成は珍しくない

- 閉域構成の経験則: **固定費**(Firewall / Private Endpoint / APIM)だけで月額の下限が決まる — 先に固定費、後から変動費

詳細: [proposal/01-hearing-sheet](#) / [proposal/02-cost-estimation](#)

日本の規制対応

定番質問への「回答型」を用意済み — 登録状況は案件ごとに最新確認

ISMAP(政府・自治体)

政府情報システムのクラウド登録制度。**対象サービスの登録状況の確認が先決** — 登録リストは変動するため文書に固定値を書かない設計

FISC(金融)

金融機関の安全対策基準。対応整理+**閉域構成(D1)**が前提になりやすい

個人情報保護法

委託構成の整理+**abuse monitoring(不正利用監視の人手レビュー)**の説明を準備 — オプトアウト申請の可否を含む

3 省 2 ガイドライン(医療)

医療情報システムの安全管理ガイドライン。該当時の論点を整理済み

- 位置づけ: **G1(データ・規制)/ G2(ネットワーク)ゲートの日本ローカル具体化**

詳細: [proposal/03-japan-compliance](#) — docs/survey/proposal/03-japan-compliance.md

公開事例

提案書で引ける事例を 21 件収録 — 公式出典のみ、数値は表現のまま使う

67%

富士通 — 営業支援エージェントで生産性
向上(Foundry 名指し)

50%

NTT データ — Fabric+Agent Service で
市場投入を短縮

4 万件/日

Air India — 問い合わせを自動処理

- ほかに Sky / 大和証券 / トヨタ / ソフトバンク / JR 西日本 / Accenture(4 か月で 17 ユースケース)など計 21 件を出典 URL つきで収録
- 事例は「**同業種・同類型で公開実績がある**」ことの証明に使い、**アーキテクチャ選定の根拠には使わない**(その役割は公式リファレンス)

詳細(正確な表現+出典 URL): [proposal/05-case-studies](#) — docs/survey/proposal/05-case-studies.md

情報の鮮度の保ち方

この情報は腐る — ウォッチすべき一次情報は 3 つだけ

What's new in Microsoft Foundry

月次の新機能・ステータス変更

features の月次更新のトリガー

Feature readiness at GA

GA / プレビューの最重要ページ

公式ページ間で表記が食い違ったらここを正とする

Model retirement schedule

モデルのリタイア日

提案書のモデル固定リスクをここで確認

- 更新サイクル: features 月次 / architecture 四半期 / proposal 随時。Ignite(11 月)・Build(5 月)直後は必ず更新
- このスライド自体も survey の大型更新に合わせて改訂する(更新手順は明文化済み・生成 AI への依頼手順つき)

詳細(更新運用ガイド・ウォッチリストの URL): [features/index](#) — docs/survey/features/README.md

まとめ

3つの判断能力を、次の案件で「この3手」から使い始める

① 決める順序

G1～G5 を後戻りコストの大きい順に閉じる

② 当たりの付け方

要件の言葉 → A1～E6 パターン+3 軸(定義方法 / フレームワーク / 統合度)

③ 見積もりの現実

「やってくれないこと 12」+廃止期限+実測のハマりどころ

1 ヒアリング

proposal/01 のシートで要件採取(太字の地雷質問だけでも)

→

2 ゲートで絞る

G1 → G5 の順に閉じ、A1～E6 の 1～2 パターンへ

→

3 裏取り

features で GA / プレビュー確認+期限表と衝突チェック

最初の 1 手のテンプレート: [proposal/01-hearing-sheet](#) / 要件の逆引きは付録 A6 — docs/survey/proposal/01-hearing-sheet.md

2 層目への入口 / Q&A

2 層目はビルド済み — リポジトリを **clone** してブラウザで開くだけ

資料	何に使う	場所
機能一覧(features)	その機能は使えるのか	<code>docs/survey/features/html/index.html</code>
設計ガイド(architecture)	どう組むか・パターン・運用	<code>docs/survey/architecture/html/index.html</code>
提案実務(proposal)	ヒアリング・コスト・規制・事例	<code>docs/survey/proposal/html/index.html</code>
技術選定ガイド	実装で実証した判断基準	<code>docs/tech-selection-guide.md</code>
学習計画(3 軸の原典)	選定の全体像	<code>docs/learning-plan.md</code>
移植ラボ(実装例 14 本)	動くコード・テスト・IaC	<code>labs/maf-ports/README.md</code>

- 以降は付録: **A1** パターン完全版 / **A2** やってこないこと全 12 項 / **A3** 期限全体表 / **A4** Copilot Studio 境界 / **A5** 16 レイヤー表 / **A6** 要件逆引き / **A7** 用語集

[features](#) / [architecture](#) / [proposal](#) / [tech-selection-guide](#) / [learning-plan](#) / [labs/maf-ports](#)

付録 A1: ユースケース別パターン完全版(A1～E6)

詳細: [architecture/index](#) — docs/survey/architecture/README.md

ID	パターン	オーケストレーション	RAG / ナレッジ	主な決め手
A1	部門内 FAQ チャット	Prompt agent	File Search	速度優先。権限制御なし
A2	全社ナレッジ検索(本番)	Prompt / Hosted agent	AI Search 自前索引	ユーザーごとに見える文書が違う
A3	既存 AI Search 資産の活用	Prompt agent	AI Search ツール直結	索引設計を自分で持ち続けたい
A4	M365 / SharePoint 主データ源	Prompt agent	SharePoint ツール(OBO)	権限透過。M365 Copilot ライセンス前提
A5	複数ソース横断・高精度	任意(MCP 経由)	Foundry IQ	複数エージェントでナレッジ共有
B1	単一エージェント+基幹 API	Prompt agent + Toolbox	補助的	参照系中心
B2	承認付き業務自動化(HITL)	MAF hosted agent	調査工程で使用	「担当者が承認してから実行」
B3	長時間・確実な再開	MAF + Durable Extension + DTS	任意	数時間～数日停止して再開
B4	マルチエージェント(専門分化)	MAF workflows / A2A	領域別	領域ごとに権限を分けたい
B5	業務フローエンジン主導	Logic Apps / Copilot Studio	任意	業務部門がビジュアルで保守
C1	一般顧客向けチャット	任意	任意	不特定多数(公開 + WAF + APIM)
C2	マルチテナント SaaS	Hosted agent(プロトコル 2.0.0)	テナント別索引	複数顧客に販売(APIM 必須)
C3	大規模・複数部門への払い出し	任意	任意	部門別按分・キャパシティ(APIM 必須)
D1	規制業種・閉域	Hosted agent or 自前	AI Search 自前索引一択	BYO VNet。閉域・監査・データ主権
D2	ソブリン(Azure Government)	Prompt agent 対応	File Search / AI Search	hosted agent・MCP・A2A 非対応
D3	エッジ・オンプレ	Foundry 非依存	自前	Foundry Local / Azure Local 版 / 切断コンテナ
E1	音声エージェント	Voice Live API	任意	リアルタイム音声対話(SIP 非対応)
E2	文書処理・IDP	非同期パイプライン	DI / Content Understanding	帳票・契約書の構造化抽出
E3	大量バッチ処理	ジョブ実行基盤	不要	Batch で 50% 割引
E4	マルチモーダル生成	非同期ジョブ	不要	画像・動画生成(閉域不可)
E5	M365 / Teams 連携	Prompt / Hosted agent	Work IQ 等	業務ツール内で使わせる
E6	ファインチューニング運用	MLOps パイプライン	併用推奨	挙動・文体をモデル側で変える

付録 A2: Foundry がやってくれないこと(全 12 項)

#	やってくれないこと	誰が埋めるか
1	リージョン間の自動フェイルオーバー・DR(復旧は再構築)	アプリ層ルーティング + Cosmos 継続バックアップ + 再構築パイプライン
2	会話へのユーザー単位の認可(BOLA)	アプリ側で所有権をリクエストごとに検証
3	エージェントの blue-green / canary	APIM 等のルーティング層
4	モデルデプロイのラウンドロビン・サーキットブレーカー	APIM のバックエンドプール + circuit breaker
5	部門・テナント別のトークン計測と課金按分	APIM llm-emit-token-metric
6	コストのハードリミット	予算アラート + 自作の自動化
7	プロジェクト内のエージェント単位のアクセス制御	アプリの認証認可層 / hosted agent の Entra Agent ID
8	max_output_tokens / truncation によるトークン制御	自前オーケストレーション
9	閉域での Traces / Memory / File Search / Work IQ / 画像生成 等	自前実装または機能除外
10	Claude モデルへのコンテンツフィルター	APIM llm-content-safety かアプリ層で Content Safety
11	音声モデルへのガードレール	テキスト化後の経路で Content Safety
12	capabilityHost の更新(変更は削除・再作成)	IaC を「作り直し前提」で設計

- 加えてコンテンツフィルターはフェイルオープン — 規制業種は finish_reason / content_filter_results の検証を必須実装に

詳細: [architecture/index\(全案件共通の前提の節\)](#) — docs/survey/architecture/README.md

付録 A3: 重要期限の全体表(features 側)

詳細: [features/index](#) — docs/survey/features/README.md

期限	対象	影響・移行先
2026-08-20	Hosted agents 初期レビュー基盤	サポート終了。新基盤へ再デプロイ必須
2026-08-26	Assistants API(Azure OpenAI)	廃止。Responses API(Agents v2)へ
2026-08-26	azure-ai-inference SDK	廃止(beta のまま GA せず終了)。OpenAI SDK + v1 API へ
2026-08-31	NTT Data tsuzumi-7b (Legacy)	廃止。後継 tsuzumi2 へ。日本語特化モデル案件で効く
2026-10-01 前後	gpt-4o / o1 / o3 / o4-mini 等の旧モデル群	リタイア
2026-10-14	gpt-4.1-nano	リタイア(gpt-4.1 / mini より約半年早い。混同しない)
2026-10-14	Azure OpenAI On Your Data	廃止。Foundry Agent Service + Foundry IQ へ
2026-12-01	ビジュアル Workflows	廃止。MAF / Logic Apps / A2A へ
2027-03-31	Agents (classic)(v1、Threads / Runs)	廃止。Agents v2 へ(状態データは自動移行されない)
2027-04-20	prompt flow	廃止。新規開発に非推奨。MAF へ
2028-09-25	Azure AI Vision Image Analysis 4.0 / 3.2	廃止。DI / Content Understanding / Foundry Models へ
日付未公表	Agent Applications / コンテナプロトコル 1.0.0	廃止予告済み(1.0.0 は 2026-07-31 からブロック開始と公表)
予告 15 日のみ	Fireworks 系モデル(FW-*)	標準 60 日でなく 15 日前通知。本番の必須経路に置かない

付録 A4: Copilot Studio との境界線(一次情報で引ける)

- Copilot Studio → Foundry(プロコード)への乗り換えシグナル 3 つ(公式ドキュメントで裏づけ):
 - 30～40 アクション超でオーケストレーターのツール選択精度が落ちる(公式明記)
 - 多段のエージェント階層が組めない(connected agents を持つエージェントは他の connected agent になれない)
 - 決定的ワークフローが業務クリティカル — CAF が「Foundry / MAF の workflows を使え」と実装先を名指し
- 選定の決め手は機能でなく「誰が作り・誰が保守し・どこまで制御が要るか」(CAF デシジョンツリー)
- 両者は排他ではない — 入口・M365 チャンネル・業務部門の保守は Copilot Studio、複雑な処理は Foundry hosted agent(connected agent として呼ぶ)が公式推奨の分業構成。SI の受託範囲を「Copilot Studio で簡単に作れないエージェントの開発」とする契約の切り方が公式構成と一致(ただし接続はプレビュー)

詳細: [architecture/11-decision-frameworks](#) — docs/survey/architecture/11-decision-frameworks.md

付録 A5: 16 レイヤー × M / H / S 完全版(Foundry 機能 vs 自前実装)

#	レイヤー	M(フルマネージド)	H(ハイブリッド)	S(自前)	迷ったら
L1	モデル提供	Foundry モデルデプロイ	+ APIM ゲートウェイ	他クラウド / セルフホスト	M
L2	オーケストレーション	Prompt agent	Hosted agent(MAF・LangGraph)	自アプリ + Responses API	H
L3	会話状態	Conversations	BYO Cosmos DB	自前 DB	M→S
L4	長期記憶	Foundry Memory(プレビュー)	Memory + 自前フィルタ	自前サマライズ + ベクトル検索	S(本番)
L5	ナレッジ / RAG	File Search / Foundry IQ	AI Search + 自前索引	自前パイプライン	H
L6	ツール実行	ツールカタログ / MCP	Toolbox + 自前 MCP	アプリ内 function calling	H
L7	コード実行	Code Interpreter	Custom CI	ACA dynamic sessions 直	M
L8	ガードレール	Guardrails 既定	カスタム	Content Safety API 自前呼び	M+S 併用
L9	ID・認可	Foundry RBAC + Entra	OBO / Agent identity	自前認可基盤	M
L10	ネットワーク	パブリック + Private Link	BYO VNet 注入	自前 VNet	要件次第
L11	ゲートウェイ	クォータのみ	APIM AI ゲートウェイ	自前プロキシ	H
L12	可観測性	Foundry Tracing	OTel 自前計装 → App Insights	自前ログ基盤	M+H
L13	評価	Foundry Evaluations	evals API を CI から	自前ハーネス	H
L14	UI・チャネル	Teams / M365 公開	自作 Web + Responses API	既存システム組込み	要件次第
L15	実行基盤	Hosted agents	Container Apps 等	AKS / オンプレ	H
L16	IaC・CI/CD	ポータル手動	Bicep / Terraform + azd	既存 IaC に統合	S

詳細(各レイヤーの全選択肢と根拠): [architecture/02-building-blocks](#) — docs/survey/architecture/02-building-blocks.md

付録 A6: 要件の言葉の逆引き表

要件の言葉	当たりをつけるパターン
「社内文書を検索して答える」	A1 で PoC → 品質が出なければ A2
「部署によって見える文書が違う」	A2(GA 要件を満たす唯一の方式)
「担当者の承認を経て実行」	B2(MAF hosted agent)。承認待ちが数日なら B3
「複数のエージェントが協調する」	B4。ビジュアル Workflows は選ばない(2026-12-01 廃止)
「顧客向けに公開する」	C1。WAF チューニングと BOLA 対策を工数に
「複数のお客様に SaaS として提供」	C2。APIM が事実上必須
「閉域で運用する」	D1。「閉域で使えない機能一覧」から設計
「日本国内でデータ処理を完結」	Regional Standard(Japan East)。APAC Data Zone は不可
「音声で対話したい」	E1(Voice Live)。SIP 非対応に注意
「請求書を読み取って」	E2。定型は DI、非定型は Content Understanding
「月間 N 万件を処理」	E3(Batch 50% 引き)+ PTU サイジング
「既存システムに組み込む」	オーケストレーションは自前(L2 の S)。Foundry の運用機能は使えなくなる
「ログイン回避」	Foundry はモデル供給元として使い、抽象レイヤーを自前で持つ

詳細: [architecture/index\(選定早見表\)](#) — docs/survey/architecture/README.md

付録 A7: 用語集(本資料で使う略語)

略語	意味
GA	General Availability(一般提供)。SLA つきの正式リリース
RAG	Retrieval-Augmented Generation。文書を検索して根拠つきで回答させる方式
HITL	Human-in-the-Loop。処理の途中に人の承認を挟む
MAF	Microsoft Agent Framework。コードでエージェントを組む公式フレームワーク
MCP	Model Context Protocol。エージェントとツールの標準接続規格
A2A	Agent-to-Agent。エージェント間連携プロトコル
BOLA	Broken Object Level Authorization。ID 指定で他人のリソースに触れる認可不備
FT	Fine-tuning。モデルの追加学習
IDP	Intelligent Document Processing。帳票・文書の構造化抽出
DI / CU	Document Intelligence(定型帳票)/ Content Understanding(非定型文書)
PTU	Provisioned Throughput Unit。スループットの予約購入
OBO	On-Behalf-Of。ユーザー本人の権限での代理アクセス
LRO	Long-Running Operation。非同期の長時間処理
SIP	Session Initiation Protocol。電話網接続の標準プロトコル

略語	意味
WAF(2 義)	Web Application Firewall(境界防御)/ Well-Architected Framework(Azure 設計原則集)。本文では都度明記
APIM	Azure API Management。API ゲートウェイ
VNet / BYO VNet	仮想ネットワーク / 自前 VNet の持ち込み(閉域構成)
PE	Private Endpoint。閉域接続の受け口
CMK	Customer-Managed Key。顧客管理キーによる暗号化
RBAC	Role-Based Access Control。ロールベースのアクセス制御
MI	Managed Identity。Azure リソースに付与する実行 ID
IaC	Infrastructure as Code。インフラ構成のコード化(Bicep / Terraform)
CAF	Cloud Adoption Framework。Microsoft のクラウド導入方法論
AAC	Azure Architecture Center。公式アーキテクチャ集
ALZ	Azure Landing Zones。全社共通の Azure 基盤標準
DPA	Data Protection Addendum。Microsoft のデータ保護補遺(契約文書)
DTS	Durable Task Scheduler。永続実行のスケジューラ
DR	Disaster Recovery。災害復旧