

Microsoft Foundry を SI で使う

技術選定とアーキテクチャ判断の基準

2026-09 改訂(第 4 版)/ 課内共有

本リポジトリの調査(survey)+実装検証(labs)の入口となる資料



今日のゴール

持ち帰るのは機能の知識ではなく、3つの「判断能力」



① 決める順序

後戻りコストの大きい順に
5つのゲート(G1~G5)で閉
じる



② 当たりの付け方

要件の言葉を
5 家族・22 パターン+選定 3
軸に当てて 1~2 案に絞る



③ 見積もりの現実

「やってくれないこと」と廃
止期限を工数・リスクに乗せ
る

方針 全機能の暗記は不要 — 「どこを見れば載っているか」が分かれば提案は書ける

用語 略語は初出でスペルアウトし、巻末の付録 **A7** に用語集を用意した

2 層目の全体像: [survey/README.md](#) — docs/survey/README.md

資料の全体像(2 層構成)

この資料は入口(1 層目) — 詳細は 2 層目の調査資産と、動くコードに降りられる

このスライド(1 層目)

判断の骨組みだけを
45 分で



features

その機能は使える
のか
GA / プレビュー
を約 200 機能・
出典つき。月次更
新

architecture

どう組むか
公式リファレンス
+22 パターン+運
用・移行。四半期
更新

casebook

どこで詰まるか
要件シナリオ 12
本+詰まりどころ
索引 約 160

proposal

どう提案するか
ヒアリング・コス
ト手順・日本規
制・公開事例

labs+選定ガイド

実装で実証できた
こと
動くコード 17 本
+実行ガイド
(runbook)

- 各スライドの下部に、該当する 2 層目へのリンクとリポジトリ内パスを常設してある
- 「公式ドキュメント調査(survey)」と「実装検証(labs)」は出典を分離 — 提案書で根拠を二本立てにできる

詳細: [features](#) / [architecture](#) / [casebook](#) / [proposal](#) / [labs 実行ガイド](#) — docs/survey/README.md

前提: Ignite 2025 の改称

検索で出てくる情報の大半は旧名義 — 新旧対応を頭に入れて読む

ブランド	Azure AI Studio / Azure AI Foundry	→	Microsoft Foundry
付帯 AI サービス	Azure AI Services	→	Foundry Tools
エージェント API	Assistants API(Threads / Runs)— 2026-08-26 廃止済	→	Responses API(Agents v2)
リソースモデル	Hub + Azure OpenAI + AI Services	→	Foundry リソース(単一)
SDK	azure-ai-inference 等 — 2026-08-26 廃止済	→	azure-ai-projects 2.x + openai
ドキュメント	/azure/ai-foundry/	→	/azure/foundry/(新)+ /azure/foundry-classic/

- 対応表なしで検索すると、**廃止済み API** の記事で設計してしまう(メンバーの過去調査も旧名義の可能性)

詳細: [features/index\(前提知識の節\)](#) — docs/survey/features/README.md

機能の全体像(8 カテゴリ)

全機能は 8 カテゴリの「地図」に整理済み — 位置だけ覚えれば引ける



01 プラットフォーム基盤

リソース / プロジェクト / アクセス制御 / ネットワーク / IaC



02 モデル

OpenAI / Claude / Grok 等 / デプロイタイプ / Model router / Foundry Local



03 Agent Service

Responses API / prompt・hosted エージェント / Memory / Routines / A2A



04 ツール・ナレッジ

File Search / AI Search / MCP / Toolbox / Foundry IQ



05 観測・評価

トレーシング / 評価器 / クラウド評価 / AI Red Teaming



06 ガードレール

コンテンツフィルター / Prompt Shields / 根拠性検出 / PII 検出



07 Foundry Tools

Speech(Voice Live)/ Document Intelligence / Content Understanding



08 開発者サーフェス

v1 API / SDK / azd / Bicep / Agent Framework / Dev Pack

- 各カテゴリとも GA / プレビュー+操作手段(ポータル / CLI / SDK / REST)を全行出典つきで整理済み

詳細: [features/index](#) — docs/survey/features/01~08-*.md

GA / プレビューの現実

「GA」を鵜呑みにしない — 選定に効く 4 つの現実(2026-09 時点)

① GA / プレビューは機能単位で混在

ポータルは GA でも中身はバラバラ。体系的な一覧は公式 **Feature readiness at GA** が唯一 — 提案前に必ず引く。公式ページ間の表記揺れ(例: Tool search は Azure ブログ GA / Learn プレビュー)は**GA 一覧表**を正とする

② GA でも足元が動き続けている

2026-09 に GA 第 2 波(**GA** Routines・A2A v1.0)。一方で hosted エージェントは 07 に GA したばかりで旧基盤は 08-20 終了済、ビジュアル Workflows は**プレビュー**のまま **12-01 廃止**

③ CLI は一級市民ではない

専用の `az foundry` は存在しない。多くの機能が「ポータル+SDK / REST のみ」 — 自動化の見積もりに直接効く。導入は **Foundry Dev Pack**(09-15 発表)で一括化


④ Claude(Anthropic)は独自制約つき

Opus 5.5 / Sonnet 5.5 まで GA(US Data Zone)。ただし Anthropic SDK+Marketplace 課金+**Foundry** 組み込みコンテンツフィルター非適用

詳細: [features/index\(ハイライトの節\)](#) — [docs/survey/features/README.md](#)

公式リファレンスアーキテクチャ

公式 3 本のうち本番の出発点は **Baseline Chat 一択(Basic は PoC 用)**



- 1 利用者は唯一の公開入口 App Gateway へ
- 2 WAF を通過しチャット UI(App Service)へ
- 3 Private Endpoint 経由でエージェントを呼ぶ
- 4 会話・ファイル・索引は自サブスクの PE 先に保持
- 5 外部ツール呼び出しは egress サブネットから
- 6 Firewall が許可した FQDN だけ外へ出す

詳細: [architecture/01-official-baselines](#) — docs/survey/architecture/01-official-baselines.md

判断①: 5 つのゲート

構成の決定は「後戻りコストの大きい順」 — 5 つのゲートを上から閉じる

後戻りコスト 大 ▲

G1 データ・規制	そのデータを、どこで、誰に処理させてよいか	モデル・デプロイタイプ・外部ツール可否が決まる
G2 ネットワーク	閉域か、パブリックか	使える Foundry 機能の一覧が決まる(後付け不可)
G3 制御	明示的な分岐・承認・再開が要るか	ポータル完結か、コードファーストかが決まる
G4 統合	既存システムとの主従はどちらか	プラットフォームとして使うか、部品として使うか
G5 ライフサイクル	いつまで、誰が保守するか	プレビュー可否・IaC の作り込み度が決まる

後戻りコスト 小 ▼

- 機能比較表から入ると G1 / G2 の手戻りで壊れる — 上から順に閉じるのがこのガイドの背骨

詳細: [architecture/03-decision-guide](https://docs.survey.architecture/03-decision-guide.md) — docs/survey/architecture/03-decision-guide.md

G1 データ・G2 ネットワーク

G1・G2 は後付けできない — 最初のヒアリングで確定させる 4 点



閉域構成は作成後に変更できない 制約

BYO VNet 注入(自前の仮想ネットワークへの組み込み)はリソース作成時のみ。後から閉域要件が出ると作り直し



閉域では使えない機能が多い 閉域

トレース(VNet はプレビュー)/ Memory / 画像生成 / ブラウザ自動化など。File Search は公式表「対応」でも実測で失敗。「閉域で使えない機能の一覧」から設計を始める



「国内処理の完結」は選択肢が 1 系統 制約

geography 型(Standard / Regional Provisioned を Japan East / West に配置)のみ。**APAC Data Zone** は **APAC** 域内のどこでも処理されうるため不可。Global 比の価格プレミアムあり



Web 検索はコンプライアンス境界の外 制約

Grounding with Bing は DPA(Microsoft のデータ保護補遺)対象外・別課金。規制業種では原則不可として扱う

詳細: [architecture/07-usecase-regulated-edge](#) — docs/survey/architecture/07-usecase-regulated-edge.md

G3~G5 と机上決定

事例がなくても構成は机上で決められる — 公式が「試作省略可」と明言



G3 制御

分岐・ループ・承認・再開の明示制御が要るならコードファースト



G4 統合

既存システムが主なら「モデルとツールだけ借りる」構成 (Responses API のみ利用)



G5 ライフサイクル

顧客内製・非開発者運用ならポータル中心。レビュー許容度もここで確定

CAF(Cloud Adoption Framework: Microsoft のクラウド導入方法論)の明言 — 「Skip prototyping: **Yes**(複数試作の比較は不要)」「クリティカルな業務ロジックには決定的ワークフローを強制せよ(Foundry / MAF=Microsoft Agent Framework)」

- 実測が要るのは**品質とコストの実額だけ** — そこは評価ハーネスで回帰可能にする

詳細: [architecture/11-decision-frameworks](#) — docs/survey/architecture/11-decision-frameworks.md

判断②: 推奨構成マップ

要件の言葉をまず 5 つの家族に当て、家族ごとの「本線」から始める




- 完全版の一覧は付録 **A1**、要件の言葉からの逆引きは付録 **A6**。以降、本線と分岐点を図で見ていく

詳細: [architecture/index\(選定早見表\)](#) — docs/survey/architecture/README.md

A1: 最小構成で始める

部門 FAQ 程度なら A1 — prompt エージェントの設定だけで動く




- 1 社員が Entra ID でサインインして質問
- 2 Web アプリがマネージド ID で agent を呼ぶ(Responses API)
- 3 agent が A1 / A3 / A4 のどれかで検索
- 4 モデルが検索結果から引用付きで回答

詳細: [architecture/04-usecase-chat-rag](#) — docs/survey/architecture/04-usecase-chat-rag.md

A2: 本番の標準形

「部署ごとに見える文書が違う」なら A2 一択 — AI Search 自前索引



- A** 文書を CU / DI で構造化して取り込む
- B** インデクサがチャンク化・埋め込み・権限を投影
- 1** 社員が Entra ID でサインインして質問
- 2** アプリがグループ ID を検索フィルタに反映
- 3** agent が Private Endpoint 経由でハイブリッド検索
- 4** 権限内のチャンクだけを使ってモデルが回答

詳細: [architecture/04-usecase-chat-rag](#) — docs/survey/architecture/04-usecase-chat-rag.md

A: ナレッジの持たせ方 5 分岐

「データの場所と権限」で決まる — 上から順に聞けば 1 つに落ちる

ユーザーごとに見える文書が違う?

はい → **A2** AI Search 自前索引(本番の標準形)

M365 / SharePoint が主データ源?

はい → **A4** SharePoint ツール(権限透過。ライセンス前提・プレビュー)

既存の AI Search 索引資産がある?

はい → **A3** AI Search ツール直結(索引設計は自前で持ち続ける)

複数ソースを複数エージェントで共有?

はい → **A5** Foundry IQ(ナレッジベース API は GA・ポータルはプレビュー)

どれも無い(小規模・静的データ)


→ **A1** File Search 最小構成

⚠ **Azure OpenAI On Your Data は 2026-10-14 廃止(あと約 2 週間)** — 「モデルが直接データを読む」構成の既存提案書は要更新(移行先: Agent Service+Foundry IQ)

詳細: [architecture/04-usecase-chat-rag](#) — docs/survey/architecture/04-usecase-chat-rag.md

B2: 承認付き業務自動化

「承認してから実行」は B2 — 承認待ちで止まり再開できる MAF ワークフロー




- 1 業務 UI から依頼(Responses API)
- 2 調査・実行案の作成でモデルを呼ぶ
- 3 承認待ちで停止し、承認者へ依頼
- 4 承認後、MCP 経由で基幹システムを操作
- 5 誰が・いつ・何を承認したかを自前ストアへ

詳細: [architecture/05-usecase-agent-automation](#) — docs/survey/architecture/05-usecase-agent-automation.md

B3: 長時間・確実な再開

承認待ちが日単位なら B3 — 再起動をまたいで確実に再開する



1 業務 UI から依頼し、ワークフローを開始

2 ステップごとの状態を DTS に保存(障害時は復元)


3 承認者へ依頼し、数時間～数日も待つ

4 承認・外部完了のイベントで待機点から再開

詳細: [architecture/05-usecase-agent-automation](#) — docs/survey/architecture/05-usecase-agent-automation.md

B4: マルチエージェント

権限を領域ごとに分けたいときだけ B4 — まず単一で始める




- 1 業務アプリから依頼 (Responses API)
- 2 MAF がパターンに沿って専門エージェントへ振り分け
- 3 各エージェントが自分の ID・権限でツール / ナレッジを使う
- 4 他組織のエージェントへは A2A v1.0 で委譲

詳細: [architecture/05-usecase-agent-automation](#) — docs/survey/architecture/05-usecase-agent-automation.md

B5: ビジュアル Workflows 廃止

ビジュアル Workflows は 12-01 廃止 — ビジュアル保守が要件なら B5




- 1 業務イベントでフローが起動(業務部門が保守)
- 2 判断部分は Foundry をモデルソースに使う
- 3 コネクタで承認・通知・SaaS 操作を実行
- 4 Copilot Studio から Foundry エージェントを呼ぶ
- 5 Foundry エージェントを Teams / M365 Copilot に公開

詳細: [architecture/05-usecase-agent-automation](#) — docs/survey/architecture/05-usecase-agent-automation.md

C2: 顧客向け公開・SaaS

主戦場は境界防御 — 会話の認可を Foundry はやってくれない




- 1 トークンからテナント ID を確定(LLM に伝搬させない)
- 2 データ API 層がそのテナントのデータだけを取得
- 3 APIM がテナント別に TPM 制限・トークン計測
- 4 既定は共有デプロイ、大口は専用デプロイへ

詳細: [architecture/06-usecase-customer-facing](#) — docs/survey/architecture/06-usecase-customer-facing.md

D1: 規制業種・閉域

閉域は「使えない機能の一覧」から設計する — 下限は固定費




- 1 社内から ER / VPN で PE へ(公開経路なし)
- 2 委任サブネットに hosted agent セッションを起動
- 3 ツール呼び出しは single-tenant の Data Proxy 経由
- 4 PE 経由で BYO データへ(PE は個別に作成)
- 5 送信は egress controls → Firewall で FQDN 許可

詳細: [architecture/07-usecase-regulated-edge](#) — docs/survey/architecture/07-usecase-regulated-edge.md

D3: エッジ・オンプレ

クラウドに出せないなら D3 — 3 つの形態から選ぶ



① 端末内のアプリに埋め込んで推論(Foundry Local)

② 社内の複数ユーザーへ推論 API を提供 (Azure Local)

③ 接続ゼロの環境で文書・音声を処理(切断コンテナ)

詳細: [architecture/07-usecase-regulated-edge](#) — docs/survey/architecture/07-usecase-regulated-edge.md

E: チャット以外の 6 類型

「索引」と「落とし穴」だけ持ち帰る — 各類型の構成図は 2 層目にある



E1 音声エージェント

Voice Live API

落とし穴 SIP(電話網接続)非対応・音声にガードレール非適用。**Japan East** に **gpt-realtime** 系なし



E2 文書処理(IDP)

定型帳票は Document Intelligence / 非定型は Content Understanding

落とし穴 後者はページ課金・BYO モデル接続必須



E3 大量バッチ

Batch デプロイ(Flex 処理はプレビュー)

課金 **50%** 引きだが 24 時間ターゲット・SLA なし



E4 画像・動画生成

非同期ジョブ

閉域 閉域不可。モデルのリタイアが早い



E5 M365 / Teams 連携

公開フロー(GA)

落とし穴 Bot Service が別途必要



E6 ファインチューニング

MLOps パイプライン

原則 知識の追加は **RAG**、挙動・文体の変更が **FT**

詳細: [architecture/08-usecase-specialized](#) — docs/survey/architecture/08-usecase-specialized.md

判断②: フレームワーク選定の 3 軸

「ポータル vs MAF vs LangGraph」と一列に並べない — 独立した 3 つの軸で決める

軸A 定義方法

Prompt エージェント — 構成のみ・フルマネージド実行

Hosted エージェント — 自前コードをデプロイ

軸B フレームワーク

MAF

LangGraph

OpenAI Agents SDK

自前コード

軸C 統合度

フル統合

Responses API のみ — モデルとツールだけ借りる

Foundry 非依存

- Hosted エージェントは **MAF 専用**ではない — LangGraph 製エージェントを Foundry にホストする構成も公式サポートの正規ルート
- 「Foundry を使うか」と「MAF を使うか」は**独立した判断**。既存システム組み込み型の SI 案件では軸C の「Responses API のみ」が重要

詳細: docs/learning-plan.md §2(技術選定の全体像) — [learning-plan.md](#)

レイヤー別「任せる / 作る」

16 のレイヤーごとに「Foundry に任せる / 自前で作る」を選ぶ — 全体表は付録 A5

凡例: **M** フルマネージド(Foundry 機能)/ **H** ハイブリッド / **S** 自前実装

L2 オーケストレーション — 迷ったら Hosted エージェント(MAF / LangGraph)

L4 長期記憶 — Foundry Memory はレビュー。本番は自前サマライズ+ベクトル検索

L5 ナレッジ / **RAG** — 本番は AI Search 自前索引(A2 と同じ判断)

L11 ゲートウェイ — 按分・レート制御が要るなら APIM(AI ゲートウェイ)

L16 IaC・CI/CD — データプレーンは Bicep の外(§5 で詳述)

M	H	S
M	H	S
M	H	S
M	H	S
M	H	S
M	H	S

- 「迷ったら」列は既定値であって正解ではない — 各レイヤーの全選択肢と根拠は 2 層目に整理済み

詳細(16 レイヤー全体): [architecture/02-building-blocks](#) / 付録 A5 — docs/survey/architecture/02-building-blocks.md

マルチエージェント協調の型

協調は 2 つの軸で 3 つの型に割り切れる — そもそも単一で始める

制御の流れをコードが決める(順序・分岐が事前に確定)

→

グラフ型 — MAF Workflow。直列・並列・分岐・ループ

LLM が相手を選び、応答が戻る

→

相談型(agent-as-tool) — エージェントをツールとして呼ぶ

LLM が相手を選び、制御が移る

→

担当交代(handoff) — サポートのエスカレーション等

原則 単一エージェントで始める — CAF はマルチにしてよい条件を 3 つに限定。Anthropic の公表値ではマルチはトークン消費 3~10 倍

実測 元アプリの「handoff」の多くは実は**固定シーケンス** — グラフ化で失うものはなく、型・テスト・可視化を得る

詳細: docs/tech-selection-guide.md §1-1 / [architecture/11\(公式 5 パターンとの対照\)](#)

フレームワーク移行コスト

他フレームワークからの書き換えは実測済み — 移行は思ったより軽い

元フレームワーク → MAF	書き換えの実態(14 本の移植から)
LangGraph(StateGraph)	ノード→Executor、条件エッジ→switch-case。型なし共有 dict が型付きメッセージになる
OpenAI Agents SDK	handoff 1 行 → 構造化出力+switch-case の数十行。ただしテスト可能になる
AG2 旧 Swarm	長寿命エージェントの「必要悪」が、ステートレスな純関数に縮退
LangChain ルーター	三段カスケード約 150 行が Foundry IQ の宣言に消滅(可観測性・単体テストは失う)
ADK + FastAPI 常時稼働	hosted エージェント化で変わるのは周辺 3 点のみ。cron 配管は Routines(GA)へ

- 共通パターン: 書き換えで元コードの欠陥が見つかる — 型付きグラフへの移植自体がコードレビューとして機能する

詳細(全 14 行+検証元): docs/tech-selection-guide.md §1-3 — [tech-selection-guide.md](#)

実証済みコードの対応表

「事例がない」には動くコードで答える — 型ごとにコード+テスト+laC+実行ガイド

直列パイプライン

[trend-analysis](#)

Executor+エッジ、進捗イベント

並列実行+合流

[mixture-of-agents](#)

fan-out / fan-in エッジ

ルーティング / トリアージ

[research-handoff](#)

構造化出力+switch-case

自己補正 RAG

[corrective-rag](#)

採点→分岐→書き換え+AI Search

評価駆動の品質ループ

[critique-loop](#)

サイクリックグラフ+クラウド評価

常時稼働+スケジュール

[hn-briefing-hosted](#)

hosted エージェント
+Routines

音声エージェント

[claim-voice-live](#)

Voice Live(3 層分離)

ガバナンス / 監査

[governed-agent](#)

middleware 3 種+ハッシュ連鎖監査

規模 maf-ports 14 本でオフラインテスト約 **545 件** — ネットワークなしで数秒で全件回る

2026-09 全ラボを **MAF 1.19 / openai 3.20** で再検証し、**実行ガイド (確認観点つき)**を整備

詳細: [labs 実行ガイド索引](#) / [labs/maf-ports/README.md\(進捗表\)](#) / [docs/tech-selection-guide.md](#) §3

判断③: やってくれないこと

「Foundry がやってくれないこと」を先に顧客と合意する — 頻出 5 つ

① 災害復旧・フェイルオーバー

リージョン間の自動切替なし。復旧は再構築 — アプリ層ルーティング + 再構築パイプラインで埋める

② 会話のユーザー単位認可

BOLA 対策なし — アプリ側で所有権をリクエストごとに検証

③ blue-green / canary 配備

エージェントの段階的リリース機能なし — APIM 等のルーティング層で

④ 部門・テナント別の課金按分

トークン計測は APIM の `llm-emit-token-metric` で自前実装

⑤ コストのハードリミット

公式明記: 機能が存在しない — 予算アラート + 自作の自動化で

⚠ フィルターはフェイルオープン

コンテンツフィルターが利用不能のとき遮断せず素通しで **HTTP 200** を返す — 規制業種は応答検証を必須実装に

- 全 12 項目は付録 A2 — 提案書の除外事項・前提条件欄にそのまま転記できる形にしてある

詳細: [architecture/index\(全案件共通の前提の節\)](#) — docs/survey/architecture/README.md

重要期限 2026-2027

提案書には賞味期限がある — 直近 4 つの廃止日は暗記する

●	●	●	●	●	●	●
2026-09-29	2026-10-14	2026-11-19	2026-12-01	2026-12-09	2027-03-31	2027-04-20
本資料の基準日	On Your Data	o1 / o3 / o3-mini / o4-mini	ビジュアル Workflows	gpt-4o(2024-05-13)	Agents (classic)	prompt flow
ここから数か月に廃止が集中	RAG の既存提案書は要更新(同日 gpt-4.1-nano もリタイア)	推論モデル旧世代。gpt-5.6 系へ	ポータルでのマルチエージェント構成が消える	後継 gpt-5.6-sol。他の版は 2027-04-14	状態データは移行されない	新規開発に非推奨・MAF へ

運用 PoC → 本番のスケジュールと**期限の衝突チェック**を提案フローに組み込む(期間内に廃止が来るなら最初から後継 API で作る)

済 Hosted 旧基盤(08-20)・Assistants API(08-26)は**期限到来済み**。Claude 4.5 世代(10-19)等を含む**全体表は付録 A3**

詳細: [architecture/10-migration-antipatterns / features/index\(期限表\)](#)

提案のアンチパターン

踏みやすい 11 個のうち代表 3 つ — 言う前・見積もる前に確認する

「ポータルで全部できます」

ポータル完結は「単一エージェント + カタログツール + 公開」まで。分岐・承認・ローカルテストは入らない

対処: ポータル完結の範囲とコードが要る範囲の線引き表を提案に添える

File Search で品質が出ないまま押し切る

チャンク・埋め込み設定は固定で、日本語長文・表主体の文書に合わないことがある

対処: PoC で難しい文書 20~30 件を測り、駄目なら早期に AI Search へ

az CLI で自動化できる前提の見積もり

専用の `az foundry` は存在せず、多くの機能はポータル + SDK / REST のみ

対処: 自動化は Bicep / Terraform(基盤) + SDK / REST(データ操作)前提で工数を積む

詳細(全 11 個): [architecture/10-migration-antipatterns](#) — docs/survey/architecture/10-migration-antipatterns.md

実装のハマりどころ

「半日溶けるポイント」は先に知っておく — 実測 3 点+2026-09 の依存関係



権限の反映が遅く・不均一 実測

RBAC の伝播は 5~15 分。Bicep 作成のプロジェクトは実行 ID にモデル操作権限が**自動付与**されない(ポータル作成は付く)— 401 の切り分けで半日溶ける



laC だけでは完結しない 実測

AI Search の索引や Memory ストアは Bicep / ARM で作れない。「**Bicep** → セットアップスクリプトの **2 段デプロイ**」が定型



Memory は「書いた直後に読めない」 実測

同期書き込みではなく**非同期処理+既定 300 秒の遅延**(LRO+debounce)— UX とテストはその前提で設計する



SDK の版は「最新」で揃わない **2026-09**

MAF の Foundry 連携パッケージは `azure-ai-projects<2.7` ・ `mcp<2` に上限固定。最新 SDK の新機能と同居できないことがある — **依存の上限を見積もり前に確認**

詳細(全 13 点+検証元): [docs/tech-selection-guide.md](#) §2(実装ナレッジ集) — [tech-selection-guide.md](#)

提案フロー

5 ステップの型に資料を対応済み — 明日から使える



- ・ ヒアリング後のアウトプット: 構成候補 1~2 案 / プレビュー依存リスト / 廃止日程との衝突チェック / 概算月額レンジ / 規制・契約の論点リスト

詳細: [proposal/index](#) / [casebook/index](#) — [docs/survey/proposal/README.md](#)

ヒアリングとコスト概算

ヒアリングは「地雷質問」から、コストは「固定費」から積む



ヒアリングシート(proposal/01)

Phase 0～7・約 30 問。太字は地雷質問(聞き漏らすと提案後に手戻り)

例: 閉域は要件か希望か / データを国外に出せるか / ユーザーごとに見えるデータが違うか / 引き渡し後は誰が運用するか



コスト見積もり手順(proposal/02)

トークン推計(日本語 ≒ 1 文字 1 トークン。エージェントは内部呼び出しで 2～5 倍)→ 構成要素チェック → 単価取得 → PTU 判断 → 削減レバー
単価はドキュメントに書かない主義(陳腐化対策)。モデル以外が過半になる構成は珍しくない

- 閉域構成の経験則: **固定費(Firewall / Private Endpoint / APIM)**だけで月額の下限が決まる — 先に固定費、後から変動費

詳細: [proposal/01-hearing-sheet](#) / [proposal/02-cost-estimation](#)

日本の規制対応

定番質問への「回答型」を用意済み — 登録状況は案件ごとに最新確認

ISMAP(政府・自治体)

政府情報システムのクラウド登録制度。対象サービスの登録状況の確認が先決 — 登録リストは変動するため文書に固定値を書かない設計

FISC(金融)

金融機関の安全対策基準。対応整理+閉域構成(D1)が前提になりやすい

個人情報保護法

委託構成の整理+**abuse monitoring**(不正利用監視の人手レビュー)の説明を準備 — オプトアウト申請の可否を含む

3 省 2 ガイドライン(医療)

医療情報システムの安全管理ガイドライン。該当時の論点を整理済み

- 位置づけ: **G1(データ・規制)/ G2(ネットワーク)**ゲートの日本ローカル具体化

詳細: [proposal/03-japan-compliance](#) — docs/survey/proposal/03-japan-compliance.md

公開事例

提案書で引ける事例を 21 件収録 — 公式出典のみ、数値は表現のまま使う

67%

富士通 — 営業支援エージェントで
生産性向上(Foundry 名指し)

50%

NTT データ — Fabric+Agent
Service で市場投入を短縮

4 万件/日

Air India — 問い合わせを自動処理

- ほかに Sky / 大和証券 / トヨタ / ソフトバンク / JR 西日本 / Accenture(4 か月で 17 ユースケース)など計 **21 件**を出典 URL つきで収録
- 事例は「**同業種・同類型で公開実績がある**」ことの証明に使い、**アーキテクチャ選定の根拠には使わない**(その役割は公式リファレンス)

詳細(正確な表現+出典 URL): [proposal/05-case-studies](https://docs.microsoft.com/ja-jp/proposal/05-case-studies) — docs/survey/proposal/05-case-studies.md

情報の鮮度の保ち方

この情報は腐る — ウォッチすべき一次情報は 3 つ+公式ブログ



What's new in Microsoft Foundry

月次の新機能・ステータス変更

features の月次更新のトリガー。
GA 発表は Azure 公式ブログにも載る



Feature readiness at GA

GA / プレビューの最重要ページ

公式ページ間で表記が食い違った
らここを正とする



Model retirement schedule

モデルのリタイア日

日付は往復改訂される — 提案書には表の版を併記

- 更新サイクル: **features** 月次 / **architecture** 四半期 / **casebook** 月次 / **proposal** 随時。 **Ignite(11 月)・Build(5 月)**直後は必ず更新
- このスライド自体も survey の大型更新に合わせて改訂する(更新手順は明文化済み・生成 AI への依頼手順つき)

詳細(更新運用ガイド・ウォッチリストの URL): [features/index](#) — docs/survey/features/README.md

まとめ

3つの判断能力を、次の案件で「この3手」から使い始める

① 決める順序

G1～G5 を後戻りコストの大きい順に閉じる

② 当たりの付け方

要件の言葉 → **推奨構成マップ(A～Eの本線)+3軸**(定義方法 / フレームワーク / 統合度)

③ 見積もりの現実

「やってくれないこと **12**」+廃止期限+実測のハマりどころ

1 ヒアリング

proposal/01 のシートで要件採取(太字の地雷質問だけでも)



2 ゲートで絞る

G1 → G5 の順に閉じ、A1～E6 の 1～2 パターンへ



3 裏取り

features で GA / プレビュー確認+期限表と衝突チェック+casebook で詰まりどころ

最初の 1 手のテンプレート: [proposal/01-hearing-sheet](#) / 要件の逆引きは付録 A6 — docs/survey/proposal/01-hearing-sheet.md

2 層目への入口 / Q&A

2 層目はビルド済み — リポジトリを **clone** してブラウザで開くだけ



機能一覧(features)

その機能は使えるのか

<docs/survey/features/html/>



設計ガイド(architecture)

どう組むか・22 パターン・運用

<docs/survey/architecture/html/>



ケースブック(casebook)

要件シナリオ・詰まりどころ
索引

<docs/survey/casebook/html/>



提案実務(proposal)

ヒアリング・コスト・規制・事例

<docs/survey/proposal/html/>



技術選定ガイド

実装で実証した判断基準

<docs/tech-selection-guide.md>



ラボ+実行ガイド

動くコード・テスト・IaC・確認観点

<labs/runbooks.html>

- 以降は付録: **A1** パターン完全版 / **A2** やってこないこと全 12 項 / **A3** 期限全体表 / **A4** Copilot Studio 境界 / **A5** 16 レイヤー表 / **A6** 要件逆引き / **A7** 用語集

[features](#) / [architecture](#) / [casebook](#) / [proposal](#) / [tech-selection-guide](#) / [labs/runbooks](#)

付録 A1-1: ユースケース別パターン完全版(A・B)

ID	パターン	オーケストレーション	RAG / ナレッジ	主な決め手
A1	部門内 FAQ チャット	Prompt agent	File Search	速度優先。権限制御なし
A2	全社ナレッジ検索(本番)	Prompt / Hosted agent	AI Search 自前索引	ユーザーごとに見える文書が違う
A3	既存 AI Search 資産の活用	Prompt agent	AI Search ツール直結	索引設計を自分で持ち続けたい
A4	M365 / SharePoint 主データ源	Prompt agent	SharePoint ツール(OBO)	権限透過。M365 Copilot ライセンス前提
A5	複数ソース横断・高精度	任意(MCP 経由)	Foundry IQ	複数エージェントでナレッジ共有
B1	単一エージェント+基幹 API	Prompt agent + Toolbox	補助的	参照系中心
B2	承認付き業務自動化(HITL)	MAF hosted agent	調査工程で使用	「担当者が承認してから実行」
B3	長時間・確実な再開	MAF + Durable Extension + DTS	任意	数時間～数日停止して再開
B4	マルチエージェント(専門分化)	MAF workflows / A2A	領域別	領域ごとに権限を分けたい
B5	業務フローエンジン主導	Logic Apps / Copilot Studio	任意	業務部門がビジュアルで保守

詳細: [architecture/index](#) — docs/survey/architecture/README.md

付録 A1-2: ユースケース別パターン完全版(C・D・E)

ID	パターン	オーケストレーション	RAG / ナレッジ	主な決め手
C1	一般顧客向けチャット	任意	任意	不特定多数(公開 + WAF + APIM)
C2	マルチテナント SaaS	Hosted agent(プロトコル 2.0.0)	テナント別索引	複数顧客に販売(APIM 必須)
C3	大規模・複数部門への払い出し	任意	任意	部門別按分・キャパシティ(APIM 必須)
D1	規制業種・閉域	Hosted agent or 自前	AI Search 自前索引一択	BYO VNet。閉域・監査・データ主権
D2	ソブリン(Azure Government)	Prompt agent 対応	File Search / AI Search	hosted agent・A2A 非対応(MCP は対応)
D3	エッジ・オンプレ	Foundry 非依存	自前	Foundry Local / Azure Local 版 / 切断コンテナ
E1	音声エージェント	Voice Live API	任意	リアルタイム音声対話(SIP 非対応)
E2	文書処理・IDP	非同期パイプライン	DI / Content Understanding	帳票・契約書の構造化抽出
E3	大量バッチ処理	ジョブ実行基盤	不要	Batch で 50% 割引
E4	マルチモーダル生成	非同期ジョブ	不要	画像・動画生成(閉域不可)
E5	M365 / Teams 連携	Prompt / Hosted agent	Work IQ 等	業務ツール内で使わせる
E6	ファインチューニング運用	MLOps パイプライン	併用推奨	挙動・文体をモデル側で変える

詳細: [architecture/index](#) — docs/survey/architecture/README.md

付録 A2: Foundry がやってくれないこと(全 12 項)

#	やってくれないこと	誰が埋めるか
1	リージョン間の自動フェイルオーバー・DR(復旧は再構築)	アプリ層ルーティング + Cosmos 継続バックアップ + 再構築パイプライン
2	会話へのユーザー単位の認可(BOLA)	アプリ側で所有権をリクエストごとに検証
3	エージェントの blue-green / canary	APIM 等のルーティング層
4	モデルデプロイのラウンドロビン・サーキットブレーカー	APIM のバックエンドプール + circuit breaker
5	部門・テナント別のトークン計測と課金按分	APIM llm-emit-token-metric
6	コストのハードリミット	予算アラート + 自作の自動化
7	プロジェクト内のエージェント単位のアクセス制御	アプリの認証認可層 / hosted agent の Entra Agent ID
8	max_output_tokens / truncation によるトークン制御	自前オーケストレーション
9	閉域での Traces / Memory / File Search / Work IQ / 画像生成 等	自前実装または機能除外
10	Claude モデルへのコンテンツフィルター	APIM llm-content-safety かアプリ層で Content Safety
11	音声モデルへのガードレール	テキスト化後の経路で Content Safety
12	capabilityHost の更新(変更は削除・再作成)	IaC を「作り直し前提」で設計(後継の capability settings 〈プレビュー〉も既存プロジェクトへの追加・変更は不可)
+	コンテンツフィルターのフェイルオープン(利用不能時は遮断せず素通しで HTTP 200)	規制業種は finish_reason / content_filter_results の検証を必須実装に

詳細: [architecture/index\(全案件共通の前提の節\)](#) — docs/survey/architecture/README.md

付録 A3-1: 重要期限(今後の期限)

期限	対象	影響・移行先
2026-10-14	Azure OpenAI On Your Data	廃止。Foundry Agent Service + Foundry IQ へ
2026-10-14	gpt-4.1-nano	リタイア(2027-04-14 延長は撤回され再前倒し。リタイア表 2026-09-21 版)
2026-10-19	Claude 4.5 世代(sonnet / opus / haiku-4-5)	リタイア
2026-11-19	o1 / o1-pro / o3 / o3-pro / o3-deep-research / o3-mini / o4-mini	リタイア(日付を 11-19 に統一。後継 gpt-5.6-sol / terra)
2026-12-01	ビジュアル Workflows	廃止。MAF / Logic Apps / A2A へ
2026-12-09	gpt-4o(2024-05-13)	リタイア(10-01 から延長。08-06 / 11-20 版は 2027-04-14)
2027-03-31	Agents (classic)(v1、Threads / Runs)	廃止。Agents v2 へ(状態データは自動移行されない)
2027-04-14	gpt-4.1 / gpt-4.1-mini	リタイア(nano は 2026-10-14 に戻った — 上の行)
2027-04-20	prompt flow	廃止。新規開発に非推奨。MAF へ
2028-09-25	Azure AI Vision Image Analysis 4.0 / 3.2	廃止。DI / Content Understanding / Foundry Models へ
日付未公表	Agent Applications	廃止予告済み
予告 15 日のみ	Fireworks 系モデル(FW-*)	標準 60 日でなく 15 日前通知 。本番の必須経路に置かない

詳細: [features/index\(重要期限\)](#) — docs/survey/features/README.md

付録 A3-2: 重要期限(到来済み — 既存資産の点検用)

期限	対象	状態・移行先
2026-08-20	Hosted agents 初期プレビュー基盤	サポート終了済。未移行なら新基盤へ再デプロイ
2026-08-26	Assistants API(Azure OpenAI)	「The Assistants API is retired」。Responses API(Agents v2)へ
2026-08-26	azure-ai-inference SDK	「retired on August 26, 2026」(beta のまま終了)。OpenAI SDK + v1 API へ
2026-08-31	NTT Data tsuzumi-7b (Legacy)	後継 tsuzumi2 へ。日本語特化モデル案件で効く
2026-09-13	Foundry IQ Serverless(Developer tier、プレビュー)	課金開始済。PoC で無料前提にしない
2026-09-15	MAI-Transcribe-1 (Speech 経由)	MAI-Transcribe-1.5 / Voice Live の mai-transcribe は MAI-Transcribe-2 を指す
2026-09-25	Global Standard の flex → standard 自動フォールバック	廃止済。Flex 非対応モデルへの service_tier: flex は HTTP 400
開始日の明記なし	hosted agent コンテナプロトコル 1.0.0	非サポート・ブロック中。2.0.0 へ

- 期限到来済みの項目は「既存の提案書・コード・IaCに残っていないか」の点検リストとして使う(labs は 2026-09-29 に点検済み)

詳細: [features/index\(重要期限\)](#) — docs/survey/features/README.md

付録 A4: Copilot Studio との境界線

乗り換えのシグナルは 3 つ — ただし両者は排他ではなく分業できる



30~40 アクション超

オーケストレーターのツール
選択精度が落ちる(公式明記)



多段の階層が組めない

connected agents を持つエ
ージェントは他の connected
agent になれない



決定的ワークフローが業務ク リティカル

CAF が「Foundry / MAF の
workflows を使え」と実装先
を名指し

Copilot Studio

入口・M365 チャンネル・業務部門が保
守する部分



Foundry hosted agent

複雑な処理(connected agent として
呼ぶ。接続はプレビュー、A2A 経由は
GA だが要検証)



SI の受託範囲

「Copilot Studio で簡単に作れないエ
ージェントの開発」 — 公式の分業構成
と一致

詳細: [architecture/11-decision-frameworks](#) — docs/survey/architecture/11-decision-frameworks.md

付録 A5: 16 レイヤー × M / H / S 完全版(Foundry 機能 vs 自前実装)

#	レイヤー	M(フルマネージド)	H(ハイブリッド)	S(自前)	迷ったら
L1	モデル提供	Foundry モデルデプロイ	+ APIM ゲートウェイ	他クラウド / セルフホスト	M
L2	オーケストレーション	Prompt agent	Hosted agent(MAF・LangGraph)	自アプリ + Responses API	H
L3	会話状態	Conversations	BYO Cosmos DB	自前 DB	M→S
L4	長期記憶	Foundry Memory(プレビュー)	Memory + 自前フィルタ	自前サマライズ + ベクトル検索	S(本番)
L5	ナレッジ / RAG	File Search / Foundry IQ	AI Search + 自前索引	自前パイプライン	H
L6	ツール実行	ツールカタログ / MCP	Toolbox + 自前 MCP	アプリ内 function calling	H
L7	コード実行	Code Interpreter	Custom CI	ACA dynamic sessions 直	M
L8	ガードレール	Guardrails 既定	カスタム	Content Safety API 自前呼び	M+S 併用
L9	ID・認可	Foundry RBAC + Entra	OBO / Agent identity	自前認可基盤	M
L10	ネットワーク	パブリック + Private Link	BYO VNet 注入	自前 VNet	要件次第
L11	ゲートウェイ	クォータのみ	APIM AI ゲートウェイ	自前プロキシ	H
L12	可観測性	Foundry Tracing	OTel 自前計装 → App Insights	自前ログ基盤	M+H
L13	評価	Foundry Evaluations	evals API を CI から	自前ハーネス	H
L14	UI・チャネル	Teams / M365 公開	自作 Web + Responses API	既存システム組込み	要件次第
L15	実行基盤	Hosted agents	Container Apps 等	AKS / オンプレ	H
L16	IaC・CI/CD	ポータル手動	Bicep / Terraform + azd	既存 IaC に統合	S

詳細(各レイヤーの全選択肢と根拠): [architecture/02-building-blocks](#) — docs/survey/architecture/02-building-blocks.md

付録 A6: 要件の言葉の逆引き表

要件の言葉	当たりをつけるパターン
「社内文書を検索して答える」	A1 で PoC → 品質が出なければ A2
「部署によって見える文書が違う」	A2 (GA 要件を満たす唯一の方式)
「担当者の承認を経て実行」	B2 (MAF hosted agent)。承認待ちが数日なら B3
「複数のエージェントが協調する」	B4 。ビジュアル Workflows は選ばない(2026-12-01 廃止)
「顧客向けに公開する」	C1 。WAF チューニングと BOLA 対策を工数に
「複数のお客様に SaaS として提供」	C2 。APIM が事実上必須
「閉域で運用する」	D1 。「閉域で使えない機能一覧」から設計
「日本国内でデータ処理を完結」	geography 型(Standard / Regional Provisioned、Japan East / West)。APAC Data Zone は不可。Global 比の価格プレミアムあり
「音声で対話したい」	E1 (Voice Live)。SIP 非対応・Japan East の提供モデルに注意
「請求書を読み取って」	E2 。定型は DI、非定型は Content Understanding
「月間 N 万件を処理」	E3 (Batch 50% 引き)+ PTU サイジング
「既存システムに組み込む」	オーケストレーションは自前(L2 の S)。Foundry の運用機能は使えなくなる
「ロックイン回避」	Foundry はモデル供給元として使い、抽象レイヤーを自前で持つ

詳細: [architecture/index\(選定早見表\)](#) — docs/survey/architecture/README.md

付録 A7: 用語集(本資料で使う略語)

略語	意味
GA	General Availability(一般提供)。SLA つきの正式リリース
RAG	Retrieval-Augmented Generation。文書を検索して根拠つきで回答させる方式
HITL	Human-in-the-Loop。処理の途中に人の承認を挟む
MAF	Microsoft Agent Framework。コードでエージェントを組む公式フレームワーク
MCP	Model Context Protocol。エージェントとツールの標準接続規格
A2A	Agent-to-Agent。エージェント間連携プロトコル(v1.0 は GA)
BOLA	Broken Object Level Authorization。ID 指定で他人のリソースに触れる認可不備
FT	Fine-tuning。モデルの追加学習
IDP	Intelligent Document Processing。帳票・文書の構造化抽出
DI / CU	Document Intelligence(定型帳票)/ Content Understanding(非定型文書)
PTU	Provisioned Throughput Unit。スループットの予約購入
OBO	On-Behalf-Of。ユーザー本人の権限での代理アクセス
LRO	Long-Running Operation。非同期の長時間処理
SIP	Session Initiation Protocol。電話網接続の標準プロトコル

略語	意味
WAF(2 義)	Web Application Firewall(境界防御)/ Well-Architected Framework(Azure 設計原則集)。本文では都度明記
APIM	Azure API Management。API ゲートウェイ
VNet / BYO VNet	仮想ネットワーク / 自前 VNet の持ち込み(閉域構成)
PE	Private Endpoint。閉域接続の受け口
CMK	Customer-Managed Key。顧客管理キーによる暗号化
RBAC	Role-Based Access Control。ロールベースのアクセス制御
MI	Managed Identity。Azure リソースに付与する実行 ID
IaC	Infrastructure as Code。インフラ構成のコード化(Bicep / Terraform)
CAF	Cloud Adoption Framework。Microsoft のクラウド導入方法論
AAC	Azure Architecture Center。公式アーキテクチャ集
ALZ	Azure Landing Zones。全社共通の Azure 基盤標準
DPA	Data Protection Addendum。Microsoft のデータ保護補遺(契約文書)
DTS	Durable Task Scheduler。永続実行のスケジューラ
DR	Disaster Recovery。災害復旧