

検証結果レポート(第2版)

Azure AI Content Understanding による 研修動画ナレッジ化と RAG 検索の精度検証

日本語の画面操作研修動画 104 本(計 72 分)を対象に、動画解析(prebuilt-videoSearch GA)→ Azure AI Search ハイブリッド検索 → RAG 回答生成の 各段の精度と、検証に要したコストを定量評価した。

作成日: 2026-09-03(第1版 2026-09-03 のレビューで見つかった評価設計の不備3点を是正して再測定。§6.5)

対象読者: 実装チーム(動画ナレッジ取り込み機能の設計・実装担当)

検証環境: Azure japaneast / Content Understanding API 2025-11-01(GA)

リポジトリ: ms-foundry-learn [labs/cu-video-rag/](#) (再現手順・全コード同梱)

1. エグゼクティブサマリ

0.44%

書き起こし CER(カスタム、94 本 micro)
prebuilt は 1.34%(発話欠落 2 本を含む。除くと 0.42%)

0.937

構成 C の hit@3
(正解動画が上位 3 位以内)

0.00 → 0.67

画面のみ情報の ans@3(正解動画限定)
書き起こしのみ → カスタムフィールド

\$12

検証の総コスト(USD、概算)
うち CU 解析 \$8.8(\$ 10)

結論。(1) CU の日本語書き起こしは CER 0.44%(カスタム 2 段)/ 0.42%(prebuilt、発話欠落 2 本を除く)と実用水準であり、音声書き起こしを別実装する必要はない。(2) ただし prebuilt アナライザーを素のまま使うと、画面にしか表示されない情報(エラーコード・設定値・連絡先など)は検索・回答にほぼ使えない(ans@3 = 0.12)。(3) **日本語カスタムフィールド(2 段アナライザー構成)を追加することで ans@3 は 0.67 まで改善**(A→C の差 +0.672 [+0.557, +0.787]*、95% 信頼区間)し、画面の値そのものは CU 出力の 100.0% に転記されていた(\$ 8.6)。ragas による end-to-end 評価でも、根拠のある質問に答えられる方向で書き起こしのみ構成を上回った。(4) CU のセグメントは書き起こしフレーズを開始時刻のセグメントに丸ごと付けるため、**単語タイムスタンプでチャンクへ再配分する実装が必要**(\$ 11 #11。seg_hit@1 が +0.117 [+0.045, +0.198]* 改善)。また prebuilt のセグメント分割が動画先頭を覆わず発話が丸ごと消える事象を観測した(\$ 11 #13。取り込み時の被覆検査が必要)。(5) 検証全体のコストは概算 \$12(うち CU 解析 \$8.8)。研修動画 1 時間あたりの CU 解析コストは prebuilt 約 \$2.68、カスタム 2 段 約 \$2.85(\$ 10.2)。実装には \$ 7 の設計(2 段アナライザー+セグメント単位チャンク+単語再配分)を推奨する。

2. 目次

1. エグゼクティブサマリ	3. 検証の目的と範囲
4. 検証構成とパイプライン	5. データセット(104 本の設計)
6. 評価方法(指標・ツール・第 1 版からの是正点)	7. 結果 1: 書き起こし精度
8. 結果 2: 検索精度・セグメント分割・画面転記率	9. 結果 3: RAG 回答品質(ragas)と棄権率
10. 処理時間とコスト	11. 実装上の注意点(詰まりどころ)
12. 制約と限界	13. 実装チームへの推奨事項 / 付録

3. 検証の目的と範囲

ヘルプデスク AI の社内ナレッジに「画面操作手順のガイド・研修動画」が含まれる場合を想定し、次の 3 点を定量的に確かめる。

1. **書き起こし精度** — Content Understanding(以下 CU)の日本語音声書き起こしは、別途 Speech to Text を実装せずに済む水準か。

2. **RAG 検索・回答精度** — CU の解析結果を AI Search に取り込んだとき、質問に答えられる検索結果・回答が得られるか。特に**ナレーションでは言及されず画面にのみ表示される情報**(エラーコード・設定値・連絡先等)を扱えるか。根拠の無い質問に捏造せず棄権できるか。

3. **コスト** — 動画 1 時間あたりの CU 解析コストと、本検証全体に要した費用。

プレビュー機能は使用しない(顧客デプロイ前提)。CU は GA API 2025-11-01 のみを使用した。

4. 検証構成とパイプライン




図 1: 検証パイプライン。CU は prebuilt-videoSearch と日本語カスタムフィールド付き 2 段アナライザーの両方で解析し、インデックス構成 A0〜D を比較する。

構成	検索インデックスの本文	ねらい
A0: 書き起こしのみ(再配分なし)	CU がセグメントに付けた transcriptPhrases をそのまま	CU の素の割り当てで起きる時間ずれの影響測定(§ 11 #11)
A: 書き起こしのみ	単語タイムスタンプでセグメントの時間範囲へ再配分した書き起こし	「音声だけで十分か」のベースライン(自前 STT 相当)
B: prebuilt-videoSearch	A + セグメント記述(Summary)	prebuilt の素の実力
C: 日本語カスタムフィールド	A + 日本語要約 + 画面内テキスト転記 + 操作列挙	B の弱点(英語記述・値の欠落)への対策
D: C + フィールド分離	C の画面内テキストを別フィールド化し重み 2.0	動画内の場面順位の改善

Azure リソース: Foundry リソース(kind AIServices、japaneast)、モデルデプロイ gpt-5.4-mini(CU 生成用・回答生成用)/ text-embedding-3-small(ベクトル)/ gpt-4.1-mini(ragas 判定用)、AI Search(basic、ja.lucene + HNSW ベクトル、ハイブリッドは RRF 統合)、Blob Storage(動画置き場)。

5. データセット(104 本の設計)

日本語のナレーション付き画面操作研修動画のオープンデータセットは調査の結果存在しなかったため(PsTuts-VQA・VideoGUI はいずれも英語)、**合成データセットを自作**した。台本・画面・操作をプログラムで生成するため、書き起こしの正解(CER の基準)とステップ境界時刻が決定的に得られる。

形態	本数	内容
ナレーション付き UI 操作	88	手作り 10 本(VPN・パスワード再設定・プリンタ等)+ 26 業務ドメイン × 手続きタイプのテンプレート生成 78 本
無音・テロップのみ	10	ナレーションなし。字幕テロップと画面表示のみ(書き起こしが空になるケース)
スライド講義型	5	講義スライド + ナレーション(UI 操作なし)
長尺・複数章構成	1	約 3 分・3 章構成(セグメント分割の質の確認用)

設計上の仕掛け: (1) 約半数の動画に「**画面のみ情報**」(ナレーションでは「画面の注意書きを確認してください」とだけ言い、値は画面にだけ出す)を配置。値は全 104 本で一意 (内線 5xxx、ERR-1xx、毎月 n 日、n 件、n 日間。**他の動画の画面・台本に部分文字列としても現れないこと**を生成時に機械検証)。(2) VPN と Wi-Fi と Web 会議など**語彙が重なる動画**を意図的に併存させ、表層一致だけでは動画を特定できないようにした。(3) 生成はシード固定で再現可能。

評価クエリは 111 問(ナレーション由来 N: 42 / 画面のみ S: 61 / 紛らわしい C: 8)+ **コーパスに根拠の無い質問 U: 8 問**(棄権率の測定用)。すべてに参照回答(ref_answer)を付与し、S タイプには回答値の文字列(answer)も付与した。

6. 評価方法(指標とツール)

6.1 書き起こし: CER(文字誤り率)

CER = 編集距離 ÷ 正解文字数。正解は台本そのもの。NFKC 正規化と空白・句読点の除去後に測定 (句読点の位置は音声認識の流儀差であり意味に影響しないため)。無音動画 10 本は対象外。prebuilt とカスタムの両方で測り、書き起こしエンジンが同一であることを確認する。

6.2 検索: 情報検索の標準指標と信頼区間

ハイブリッド検索(BM25 + ベクトル、RRF 統合)の top-5 に対して、hit@1 / hit@3(正解動画のチャンクが 1 位 / 3 位以内)、MRR、seg_hit@1(1 位チャンクの時間範囲が正解場面と重なる)、**ans@k(正解動画のチャンクの本文に回答値そのものが含まれる)**を測る。ans@k は「検索が当たったように見えても本文に値がなければ RAG は答えを生成できない」を測る本検証の中心指標である。構成間の差は同一クエリ集合での**対応ありブートストラップ(2,000 回)の 95% 信頼区間**で示し、区間が 0 を含まないものを有意(*)とする。

6.3 CU 出力そのものの品質: セグメント境界一致と画面転記率

検索を介さず CU 出力を直接測る 2 指標を追加した。**セグメント境界一致**は、CU セグメントの開始時刻と正解ステップ境界が ±2 秒以内で対応する割合(recall = 正解境界のうち CU 境界があるもの、precision = CU 境界のうち正解境界に対応するもの)。**画面転記率**は、仕込んだ画面のみ情報 67 件のうち、値が CU の生成フィールドに一字一句現れた割合(found_any)と、表示された場面のセグメントに現れた割合(found_in_step)。

6.4 RAG 回答品質: ragas と棄権率

RAG 評価の標準ライブラリ **ragas 0.4.3** を使用。検索 top-3 をコンテキストに gpt-5.4-mini で日本語回答を生成し(コンテキスト外は「分かりません」と答える指示)、LLM-as-a-judge(gpt-4.1-mini、温度 0)で 5 指標を測定した: faithfulness(コンテキストへの忠実性)/ answer_relevancy(質問への適合)/ context_precision(上位コンテキストの適合率)/ context_recall(参照回答の根拠の網羅)/ answer_correctness(参照回答との一致)。加えて、根拠の無い U タイプ 8 問への **棄権率**(「分かりません」と答えた割合。高いほど良い)と、正解のある質問への棄権率 (低いほど良い)を測る。

6.5 第 1 版(2026-09-03)からの是正点

第 1 版のレビューで見つけた評価設計の不備を是正し、全指標を再測定した。第 1 版の数値との差は主に次の 3 点による。

1. **回答値の衝突** — テンプレート生成の仕込み値が動画間で重複していた(「毎月 3 日」が 10 本、「14 日間」等が 2 本ずつ。S クエリ 61 問中 16 問)。値を全動画で一意にし(部分文字列の重なりも排除)、該当 21 本を再生成・再解析した。
2. **ans@k の定義** — 旧定義は「top-k のどれかに回答値があるか」で、別動画の同じ値でも ヒット扱いになっていた。**正解動画のチャンクに限定**する定義に改めた(旧定義は ans@3(any) として参考掲載)。
3. **チャンクの時間ずれ** — CU はセグメントの transcriptPhrases を「フレーズの開始時刻が属する セグメント」に丸ごと付け、境界で分割しない(104 本 277 セグメント中 115 が書き起こし空)。単語タイムスタンプでセグメントへ再配分する処理を追加した(構成 A0 = 再配分なし、A = あり)。

また、U タイプの棄権率・セグメント境界一致・画面転記率・構成間差の信頼区間・コストを新たに測定した。

7. 結果 1: 書き起こし精度(CER)

prebuilt-videoSearch の書き起こし(transcriptPhrases)で測定。カスタム 2 段アナライザーは 0.44%(94 本)。書き起こしエンジンは共通で、差は § 7 末尾の「発話欠落」の有無による。

1.34%

micro CER(94 本合算)
発話欠落 2 本を除くと
0.42%

0.00%

中央値

1.20%

90 パーセンタイル

69

CER 0%(完全一致)の本数

誤りの大半は表記ゆれ(「二」→「2」「プリンタ」→「プリンター」等)で、意味を変える誤認識は同音のドメイン語(「社給」→「社級」「有線」→「優先」「上長」→「冗長」等)に集中する。実運用ではカスタム語彙・後段の用語正規化で対処する典型パターンである。

CER 上位(誤りが多い動画)

動画	CER	編集数 / 文字数
password-reset	46.15%	126 / 273
g67-portal-cancel	17.99%	25 / 139
slide-files	10.58%	20 / 189
newhire-orientation	1.86%	8 / 431
g06-elearn-config	1.75%	3 / 171

外れ値の内訳。slide-files は台本に含まれる記号・英字(「日付_案件_内容」「v1,v2)」の読み上げ形との差で、**正解データ側のアーティファクト**であり CU の誤りではない。それ以外の大きな外れ値は**発話の欠落**で、同一音声を 2 つのアナライザーで書き起こした CER の差(5 ポイント超)として検出できる:

動画	CER prebuilt	CER カスタム	prebuilt の先頭欠落 / 末尾ギャップ / セグメント数	カスタム
password-reset	46.2%	1.8%	23.6 s / 3.4 s / 1	0.9 s / 3.4 s / 3
g67-portal-cancel	18.0%	0.0%	0.9 s / 7.1 s / 2	0.9 s / 4.5 s / 2

prebuilt-videoSearch が password-reset を「23.6 秒から始まる 1 セグメント」で返し、先頭 2 ステップの発話が出力から消えた(§ 11 #13)。同じ動画は第 1 版の解析では CER 1.8% だったので、セグメント分割の揺れで発話が丸ごと落ちることがある。末尾側の欠落(g67-portal-cancel、最終文 25 文字)は 2 回とも再現した。これらを除く動画の CER はおおむね 2% 未満に収まる。

注意: 本データセットは合成音声(単一話者・雑音なし・鮮明な画面)であり、CER は実収録動画に対する**上限性能**として読むこと。実案件では実動画でのパイロット測定を挟む。

8. 結果 2: 検索精度・セグメント分割・画面転記率

8.1 構成 A0~D の比較(全 111 クエリ)

構成	hit@1	hit@3	MRR	seg_hit@1	ans@1(S)	ans@3(S)	参考: ans@3(any)
A0: 書き起こしのみ(再配分なし)	0.577	0.811	0.686	0.378	0.000	0.000	0.000
A: 書き起こしのみ	0.622	0.865	0.727	0.495	0.000	0.000	0.000
B: prebuilt-videoSearch	0.667	0.856	0.760	0.595	0.098	0.115	0.115
C: 日本語カスタムフィード	0.730	0.937	0.826	0.595	0.557	0.672	0.672
D: C + screenTexts 重み付け	0.739	0.937	0.825	0.595	0.574	0.689	0.689

ans@3(any) は動画を問わない旧定義。値を一意化した後も差が残るのは、回答値の一部 (例: 数字 2 桁) が他動画の本文に偶然含まれるため、正解動画限定の ans@3 を正とする。




図 2: 検索指標の構成間比較(全クエリ)。




図 3: 画面のみ情報(S タイプ 61 問)の回答値含有率(正解動画のチャンク限定)。書き起こしのみ(A)では原理的に取れず、カスタムフィールド(C/D)で大きく改善する。

8.2 構成間の差と 95% 信頼区間(対応ありブートストラップ、* = 有意)

比較 (後 - 前)	hit@1	hit@3	mrr	seg_hit@1	ans@1(S)	ans@3(S)
A → C	+0.108 [+0.009, +0.207]*	+0.072 [+0.000, +0.144]	+0.098 [+0.024, +0.173]*	+0.099 [+0.000, +0.198]	+0.557 [+0.426, +0.689]*	+0.672 [+0.557, +0.787]*
B → C	+0.063 [-0.027, +0.153]	+0.081 [+0.009, +0.153]*	+0.065 [+0.003, +0.131]*	+0.000 [-0.099, +0.099]	+0.459 [+0.328, +0.607]*	+0.557 [+0.426, +0.689]*
C → D	+0.009 [-0.045, +0.063]	+0.000 [-0.036, +0.036]	-0.001 [-0.035, +0.033]	+0.000 [-0.054, +0.054]	+0.016 [-0.033, +0.066]	+0.016 [-0.033, +0.082]
A0 → A	+0.045 [-0.018, +0.108]	+0.054 [+0.000, +0.117]	+0.041 [-0.000, +0.082]	+0.117 [+0.045, +0.198]*	+0.000 [+0.000, +0.000]	+0.000 [+0.000, +0.000]

A→C は hit@1・mrr・ans@1(S)・ans@3(S) で有意、hit@3・seg_hit@1 は区間下限が 0 に接する境界的な改善。C→D(screenTexts 重み付け)は有意差なし(動画内順位と動画間判別のトレードオフで相殺)。
A0→A(単語再配分)は seg_hit@1 を有意に改善する。

8.3 構成 C で ans@3 を外した S クエリの内訳(20 / 61 問)

原因	件数	意味・対策
検索ミス(正解動画が top-3 外)	6	ハイブリッド検索の改善余地(クエリ拡張・上位 k 拡大)
正解動画は当たったが、値を持つセグメントが top-3 外	14	同一動画の別セグメントが上位を占有。動画単位の重複排除や「動画→セグメント」の 2 段検索で改善可能
値そのものが CU 出力に無い(転記漏れ)	0	視覚転記の取りこぼし(§ 8.6 の直接測定と整合)

8.4 動画形態別(構成 A vs C)

構成	形態	n	hit@1	hit@3	MRR	seg_hit@1
A: 書き起こしのみ	長尺・複数章構成	4	1.000	1.000	1.000	0.500
A: 書き起こしのみ	ナレーション付き UI 操作	93	0.645	0.925	0.766	0.516
A: 書き起こしのみ	無音・テロップのみ	8	0.000	0.000	0.000	0.000
A: 書き起こしのみ	スライド講義型	6	0.833	1.000	0.917	0.833
C: 日本語カスタムフィールド	長尺・複数章構成	4	1.000	1.000	1.000	0.500
C: 日本語カスタムフィールド	ナレーション付き UI 操作	93	0.710	0.925	0.810	0.570
C: 日本語カスタムフィールド	無音・テロップのみ	8	0.625	1.000	0.792	0.625
C: 日本語カスタムフィールド	スライド講義型	6	1.000	1.000	1.000	1.000

無音(テロップのみ)動画は書き起こしが空になるため、構成 A では索引にすら入らない。視覚情報を扱う構成 C で初めて検索対象になる点が形態別比較の要点である。

8.5 セグメント分割の質(正解ステップ境界との一致、±2 秒)

アナライザー	セグメント数(104 本)	セグメント/ステップ	境界 recall	境界 precision	F1	時間軸被覆(平均 / 最小)	先頭 3 秒超の欠落
prebuilt-videoSearch	291	0.68	0.540	0.957	0.691	0.880 / 0.564	1
カスタム(videoSearchJa)	312	0.73	0.605	0.942	0.737	0.878 / 0.798	0

形態(カスタム)	本数	セグメント/ステップ	境界 recall	境界 precision
長尺・複数章構成	1	0.62	0.571	1.000
ナレーション付き UI 操作	88	0.71	0.571	0.927
無音・テロップのみ	10	0.85	0.800	1.000
スライド講義型	5	0.83	0.789	1.000

CU の分割は正解ステップより粗く(1 ステップ $\approx$ 1.4 セグメント)、切る位置は正確(precision 0.94)だが切り漏らしがある(recall 0.60)。時間軸被覆の平均 0.88 は末尾の無音(約 5 秒)がセグメントに入らないためで欠落ではないが、先頭側の欠落(prebuilt で 1 本)は発話の消失を伴う(§ 7、§ 11 #13)。セグメント=チャンクの設計では、1 チャンクに複数手順が入ることを前提に回答生成側で「場面(分:秒)」を引用させるのが実務的である。

8.6 画面のみ情報の転記率(CU 出力の直接測定、67 件)

アナライザー	n	found_any(どこかのセグメントに一字一句)	found_in_step(表示場面のセグメントに)	書き起こしにも出現
prebuilt-videoSearch(Summary)	67	0.179	0.179	0.000
カスタム(screenTexts 等)	67	1.000	1.000	0.000

形態(カスタム)	n	found_any	found_in_step
長尺・複数章構成	2	1.000	1.000
ナレーション付き UI 操作	51	1.000	1.000
無音・テロップのみ	13	1.000	1.000
スライド講義型	1	1.000	1.000

カスタムフィールド(screenTexts)は仕込んだ値の 100.0% を一字一句転記できた(720p 画面の 25~40px 文字。1 FPS・512×512 縮小でも読めた)。転記漏れ 0 件: なし。「書き起こしにも出現」が 0 であることは、S タイプの仕掛け(値は画面にしか無い)が成立している検査である。

9. 結果 3: RAG 回答品質(ragas)と棄権率

ragas 指標	構成 A(書き起こしのみ)	構成 C(カスタムフィールド)
faithfulness	0.964	0.860
answer_relevancy	0.172 (有効 102)	0.325 (有効 98)
llm_context_precision_with_reference	0.481	0.734
context_recall	0.405	0.802
answer_correctness	0.406	0.589




図 4: ragas 5 指標の比較(n=111、判定 LLM: gpt-4.1-mini)。

9.1 棄権率(根拠の無い質問に「分かりません」と答えられるか)

構成	U タイプ(根拠なし)の棄権率 ↑	正解あり質問の棄権率 ↓	うち S タイプの棄権率 ↓
A: 書き起こしのみ	1.000(8 問)	0.568(111 問)	0.951
C: 日本語カスタムフィールド	1.000(8 問)	0.297(111 問)	0.475

根拠の無い質問 8 問はいずれの構成でも 100% 棄権し(捏造なし)、正解のある質問への不要な棄権は A の 57% から C の 30% に減った。

読み方の注意(指標の性質)。 (1) 構成 A の faithfulness が高い(0.96)のは、コンテキストに根拠が無いとき「分かりません」と答える設計のため (A の回答の 63/111 問が「分かりません」、C は 33/111 問)。無回答は捏造ゼロ=忠実と評価されるので、faithfulness は **context_recall / answer_correctness / 棄権率とセット**で読む必要がある。(2) answer_relevancy は「分かりません」型の回答を 0 と評価する仕様に加え、本環境では判定 LLM が要求 3 生成に対し 1 生成しか返さず(ragas の警告)、短い事実回答(「PR-8600 Series です」等)にも低い値が付いた。また埋め込み呼び出しの一時的な 404(DeploymentNotFound)で一部サンプルが欠損した (表の「有効 n」)。本データでは信頼性が低いため**参考値**とし、構成間の相対比較にのみ用い

る。(3) 総合すると、C は A に対して context_precision +0.25 / context_recall +0.40 / answer_correctness +0.18 と、「答えるべき質問に答えられる」方向で一貫して優位。

10. 処理時間とコスト

10.1 処理時間

項目	prebuilt-videoSearch	カスタム(videoSearchJa)
計測本数(analyze 実行分)	104	104
1 本あたり中央値	31 秒	41 秒
1 本あたり p90	61 秒	61 秒
実時間比(中央値/動画長)	0.83 倍	0.93 倍

CU の解析は非同期(Operation-Location ポーリング)。バッチ取り込みでは並列実行できるが、紐づけた補完モデルデプロイの TPM が律速になる(§ 11)。

10.2 コスト

CU の課金は「動画コンテンツ抽出(時間課金)+ 標準コンテキスト化トークン + 紐づけたモデルデプロイのトークン(Foundry 側に計上)」の 3 階建て(pricing-explainer)。各解析の usage (videoHours / contextualizationTokens / tokens)を合算し、Azure Retail Prices API(japaneast, USD, 2026-09-03 取得)の単価で概算した。単価(USD): CU 動画抽出 1.00/時間、標準コンテキスト化 1.00/1M トークン、gpt-5.4-mini 入力 0.75 / 出力 4.50/1M、gpt-4.1-mini 入力 0.40 / 出力 1.60/1M、text-embedding-3-small 0.02/1M、AI Search Basic 0.133/時間、Neural TTS 15/1M 文字。

(a) 104 本(計 72.5 分)を 1 回解析するコスト(現在のコーパス、実測 usage)

アナライザー	本数	動画時間	コンテキスト化	モデル入力 / 出力	抽出 \$	コンテキスト化 \$	モデル \$	合計 \$
prebuilt-videoSearch	104	1.264 h	1.22 M	0.95 M / 0.043 M	1.26	1.22	0.91	3.39
カスタム 2 段	104	1.264 h	1.22 M	1.06 M / 0.073 M	1.26	1.22	1.12	3.61

→ 研修動画 1 時間あたり prebuilt 約 \$2.68、カスタム 2 段約 \$2.85 (gpt-5.4-mini Global)。カスタムの増分はモデルの出力トークン(日本語要約・転記)によるもので、コンテンツ抽出・コンテキスト化はアナライザーによらず同額。

(b) 本検証に要したコスト(概算)

区分	費目	金額 (USD)	根拠
対応前(ラウンド 1～2、2026-09- 02)	CU 解析(104 本 × 2 ア ナライザー)	7.01	対応前に保存した usage の合算
	回答生成(gpt-5.4- mini、111 問 × 2 構成)	0.11	未記録のため対応後の実測を按分(代用)
	ragas 判定(gpt-4.1- mini、111 問 × 2 構成)	1.05	同上(同一 n・同一指標)
	AI Search Basic(2.73 時 間)+ 埋め込み	0.37	Activity Log 実測: 環境 1 = 13:06～13:45Z(0.65h)、環境 2 = 14:05～16:10Z(2.08h)。AI Search Basic の稼働時間
	音声合成(Neural TTS、 17,294 文字)	0.26	台本の総文字数
対応後(ラウンド 3、2026-09-03)	CU 再解析(26 本 × 2)	1.84	timings の usage(実測)
	回答生成 + ragas 判定 + 埋め込み	1.17	usage_other.json(実測トークン)
	AI Search Basic(1.08 時 間)	0.14	環境の作成～削除時刻
合計		11.94	Storage・Foundry リソースの固定費は 0(従量のみ)

- ・ CU の usage は対応前に保存されていた最終結果 104 本 × 2 アナライザーの analyzerResults から合算
(ラウンド 1 のアナライザー試行錯誤で上書きされた解析分は含まない = 下限値)
- ・ 失敗した解析(defaults 未登録による 99 本の失敗、429)はコンテンツ抽出・コンテキスト化とも課金対象
外(pricing-explainer)
- ・ 回答生成(gpt-5.4-mini)と ragas 判定(gpt-4.1-mini)のトークンは対応前は記録していないため、同一設定
で計測した対応後の値をクエリ数で按分して代用
- ・ Cost Management(実課金 API)は本レポート作成時点で当日分が未集計(429 / 反映待ち)のため、本表は
usage × 定価の概算。実課金は EA/CSP 契約の割引率で変わる。

11. 実装上の注意点(検証中に実際に踏んだ詰まりどころ)

#	事象	対処
1	defaults へのモデル登録をモデル名で行うと、PATCH は成功するのに analyze が失敗する	prebuilt アナライザーが参照する エイリアス名 (prebuilt-analyzer-completion-mini 等)をキーに登録する。エラーは analyze 時まで遅延する
2	カスタムアナライザーの base に prebuilt-videoSearch を指定すると 400	base に使えるのは基底 4 種のみ(prebuilt-video 等)
3	親アナライザーの fieldSchema がセグメントに適用されない	フィールドを持つサブアナライザーを作り、親の contentCategories から参照する 2 段構成 にする(公式 analyzer-reference に記載)
4	カスタムアナライザーで models.completion を省くと analyze が失敗	モデル名(デプロイ名ではない)を明示する
5	既存アナライザー ID への PUT は変更が黙って無視される	実質イミュータブル。更新は DELETE → 再作成
6	解析の並列実行で 429(RateLimit)が analyze の失敗として返る	CU 自体でなく補完デプロイの TPM 律速。クォータ増強+指数バックオフ再試行を実装
7	omitContent: true とフィールド定義は併用不可(400)	omitContent: false にする
8	defaults・カスタムアナライザーは Bicep に乗らない データプレーンの状態。環境再作成時に登録を忘れると解析が全滅する	セットアップスクリプトに defaults 登録(エイリアス込み)とアナライザー作成を含めて固定化
9	ソフト削除 → パージ → 同名再作成 したリソースでは CU の解析が「deployment or resource was not found(404)」で失敗し続けた(外部からのモデル呼び出しは正常)	別名でリソースを作り直すと即解消。検証環境の再作成は同名を避ける(公式未記載の実測)
10	フレームは約 1 FPS・512×512 に縮小され、小さい文字が落ち得る(公式記載)	本検証の画面文字(25~40px/720p)は 100% 転記できた。実動画では文字サイズに注意
11	セグメントの transcriptPhrases はフレーズの開始時刻のセグメントに丸ごと付き、境界で分割されない 。無音の短い話し方だと 1 フレーズが 20~30 秒に伸び、隣のセグメントの書き起こしが空になる(277 セグメント中 115 が空)。「セグメント=チャンク」で索引すると本文と時刻がずれる	各フレーズの words[] (単語タイムスタンプ)でセグメントの時間範囲へ再配分してからチャンク化する。 効果: seg_hit@1 +0.117 [+0.045, +0.198]*(A0→A、95% CI)
12	コストの実測には analyzerResults の usage を保存しておく	videoHours / contextualizationTokens / tokens(モデル別入出力)が返る。失敗した解析は課金対象外(公式)。本レポートの § 10.2 はこの合算

13	セグメントが動画の先頭を覆わないと、その区間の発話が transcriptPhrases にも markdown にも出ない(password-reset: 先頭 23.6 秒・2 ステップ分が欠落、CER 46%。同じ動画が別の実行では 1.8%)。末尾でも最終文の欠落を観測。prebuilt ではセグメントの時間重複も起き、同じフレーズが 2 セグメントに付く	取り込み時にセグメントの時間軸被覆(先頭開始 = 0、大きな隙間なし)を検査し、低い動画は再解析するか書き起こしを分割なしアナライザーで取り直す。フレーズ・単語は(開始, 終了, テキスト)で重複除去する。同一音声で 2 系統で書き起こして CER 差を見るのが安価な健全性検査
----	---	---

12. 制約と限界

- **合成データ:** 実収録より条件が良い(単一話者・雑音なし・非圧縮画面)。CER・画面文字の転記率は上限性能。実案件では実動画でパイロット測定を行うこと(本パイプラインは流用可能)。
- **規模:** 104 本・111 クエリでの測定。S タイプ 61 問の信頼区間幅は ±0.1 程度あり、数 % 単位の差は有意でない (§ 8.2)。数千本規模ではベクトル索引のチューニング (フィルタ・セマンティックランカー等) の追加検討が必要。
- **LLM-as-a-judge:** ragas の値は判定 LLM(gpt-4.1-mini)に依存する相対比較として読むこと。answer_relevancy は本データでは信頼性が低い (§ 9)。
- **コスト**は usage × 定価の概算で、契約割引・為替・単価改定で変わる。対応前の回答生成・判定トークンは未記録のため対応後の実測で代用している。

13. 実装チームへの推奨事項

1. **採用構成は C**(日本語カスタムフィールド、2 段アナライザー)。top-3 を LLM に渡す標準的な RAG で ans@3 = 0.67。D(フィールド重み付け)は ans@k を有意に改善せず動画間の切り分けを悪化させるトレードオフがあり、top-1 しか使えない場合のみ検討。
2. 書き起こしの別実装(Speech SDK 等)は不要。CU の出力(transcriptPhrases)をそのまま使う。
3. チャンク単位は CU のセグメント。ただし **transcriptPhrases は words[] の時刻でセグメントへ再配分**してから本文にする(#11)。時間範囲(startTimeMs/endTimeMs)をメタデータに持たせ、回答には「動画名 + 分:秒」を引用させる。
4. フィールド設計 3 点セット: 日本語要約(summaryJa)/ 画面内テキストの一字一句転記(screenTexts) / 操作列挙(uiActions)。description は「ミニプロンプト」として具体例を列挙する。
5. バッチ取り込みは並列数と補完デプロイの TPM クォータをセットで設計し、429 再試行を必ず入れる。解析ごとの usage を保存してコストを実測する(1 時間あたり約 \$2.85 が目安)。
6. 同音ドメイン語の誤認識(社給→社級 等)に備え、用語正規化辞書を後段に用意する。
7. 回答生成には「根拠が無ければ分からないと答える」指示を入れる(U タイプ棄権率 100%)。評価には根拠の無い質問を必ず含める。

付録: 参照資料

- CU REST クイックスタート: learn.microsoft.com/azure/ai-services/content-understanding/quickstart/use-rest-api

- CU what's new(GA 2025-11-01): learn.microsoft.com/azure/ai-services/content-understanding/whats-new
- CU video 概要(1 FPS / 512×512 等の制約): learn.microsoft.com/azure/ai-services/content-understanding/video/overview
- CU アナライザーリファレンス(contentCategories / fieldSchema): learn.microsoft.com/azure/ai-services/content-understanding/concepts/analyzer-reference
- CU 課金モデル(usage の読み方): learn.microsoft.com/azure/ai-services/content-understanding/pricing-explainer
- 単価: Azure Retail Prices API [prices.azure.com/api/retail/prices\(japaneast、USD\)/](https://prices.azure.com/api/retail/prices(japaneast、USD)/)
azure.microsoft.com/pricing/details/content-understanding/
- AI Search ハイブリッド検索(RRF): learn.microsoft.com/azure/search/hybrid-search-overview
- AI Search スコアリングプロファイル: learn.microsoft.com/azure/search/index-add-scoring-profiles
- ragas ドキュメント: docs.ragas.io
- データセット調査(PsTuts-VQA / VideoGUI): github.com/adobe-research/PsTuts-VQA-Dataset ほか。詳細は docs/dataset-research.md

本レポートの数値はすべてリポジトリ `labs/cu-video-rag/logs/` の評価出力から機械的に転記したもの (gen_report.py)。再現手順は README.md を参照。