

検証結果レポート

Azure AI Content Understanding による 研修動画ナレッジ化と RAG 検索の精度検証

日本語の画面操作研修動画 104 本(計 72 分)を対象に、動画解析(prebuilt-videoSearch GA)→ Azure AI Search ハイブリッド検索 → RAG 回答生成の 各段の精度を定量評価した。

作成日: 2026-09-03

対象読者: 実装チーム(動画ナレッジ取り込み機能の設計・実装担当)

検証環境: Azure japaneast / Content Understanding API 2025-11-01(GA)

リポジトリ: ms-foundry-learn [labs/cu-video-rag/](#) (再現手順・全コード同梱)

1. エグゼクティブサマリ

0.60%

書き起こし文字誤り率
(CER)
94 本 micro 平均

0.955

構成 C の hit@3
(正解動画が上位 3 位以内)

0.00 → 0.74

画面のみ情報の ans@3
書き起こしのみ → カスタ
ムフィールド

0.790

RAG 回答の faithfulness
(ragas / 構成 C)

結論。 (1) CU の日本語書き起こしは CER 0.60% と実用水準であり、音声書き起こしを別実装する必要はない。 (2) ただし prebuilt アナライザーを素のまま使うと、画面にしか表示されない情報 (エラーコード・設定値・連絡先など) は検索・回答にほぼ使えない (ans@3 = 0.12)。 (3) **日本語カスタムフィールド(2 段アナライザー構成)を追加することで ans@3 は 0.74 まで改善し**、ragas による end-to-end 評価でも全指標で書き起こしのみ構成を上回った。実装には § 7 の設計(2 段アナライザー+セグメント単位チャンク)を推奨する。

2. 目次

1. エグゼクティブサマリ	3. 検証の目的と範囲
4. 検証構成とパイプライン	5. データセット(104 本の設計)
6. 評価方法(指標とツール)	7. 結果 1: 書き起こし精度
8. 結果 2: 検索精度	9. 結果 3: RAG 回答品質(ragas)
10. 処理時間	11. 実装上の注意点(詰まりどころ)
12. 制約と限界	13. 実装チームへの推奨事項 / 付録

3. 検証の目的と範囲

ヘルプデスク AI の社内ナレッジに「画面操作手順のガイド・研修動画」が含まれる場合を想定し、次の 2 点を定量的に確かめる。

- 書き起こし精度** — Content Understanding(以下 CU)の日本語音声書き起こしは、別途 Speech to Text を実装せずに済む水準か。
- RAG 検索・回答精度** — CU の解析結果を AI Search に取り込んだとき、質問に答えられる検索結果・回答が得られるか。特に**ナレーションでは言及されず画面にのみ表示される情報**(エラーコード・設定値・連絡先等)を扱えるか。

プレビュー機能は使用しない(顧客デプロイ前提)。CU は GA API 2025-11-01 のみを使用した。

4. 検証構成とパイプライン




図 1: 検証パイプライン。CU は prebuilt-videoSearch と日本語カスタムフィールド付き 2 段アナライザーの両方で解析し、インデックス構成 A〜D を比較する。

構成	検索インデックスの本文	ねらい
A: 書き起こしのみ	CU の transcriptPhrases のみ	「音声だけで十分か」のベースライン(自前 STT 相当)
B: prebuilt-videoSearch	A + セグメント記述(Summary)	prebuilt の素の実力
C: 日本語カスタムフィールド	A + 日本語要約 + 画面内テキスト転記 + 操作列挙	B の弱点(英語記述・値の欠落)への対策
D: C + フィールド分離	C の画面内テキストを別フィールド化し重み 2.0	動画内の場面順位の改善

Azure リソース: Foundry リソース(kind AIServices、japaneast)、モデルデプロイ gpt-5.4-mini(CU 生成用)/ text-embedding-3-small(ベクトル)/ gpt-4.1-mini(ragas 判定用)、AI Search(basic、ja.lucene + HNSW ベクトル、ハイブリッドは RRF 統合)、Blob Storage(動画置き場)。

5. データセット(104 本の設計)

日本語のナレーション付き画面操作研修動画のオープンデータセットは調査の結果存在しなかったため(PsTuts-VQA・VideoGUI はいずれも英語)、**合成データセットを自作**した。台本・画面・操作をプログラムで生成するため、書き起こしの正解(CER の基準)とステップ境界時刻が決定的に得られる。

形態	本数	内容
ナレーション付き UI 操作	88	手作り 10 本(VPN・パスワード再設定・プリンタ等)+ 26 業務ドメイン × 手続きタイプのテンプレート生成 78 本
無音・テロップのみ	10	ナレーションなし。字幕テロップと画面表示のみ(書き起こしが空になるケース)
スライド講義型	5	講義スライド + ナレーション(UI 操作なし)
長尺・複数章構成	1	約 3 分・3 章構成(セグメント分割の質の確認用)

設計上の仕掛け: (1) 約半数の動画に「**画面のみ情報**」(ナレーションでは「画面の注意書きを確認してください」とだけ言い、値は画面にだけ出す)を配置。値は動画ごとに一意(内線 5xxx、ERR-1xx 等)とし、100 本規模でも回答値が衝突しない。(2) VPN と Wi-Fi と Web 会議など**語彙が重なる動画**を意図的に併存させ、表層一致だけでは動画を特定できないようにした。(3) 生成はシード固定で再現可能。

評価クエリは 111 問(ナレーション由来 N: 42 / 画面のみ S: 61 / 紛らわしい C: 8)。すべてに参照回答 (ref_answer)を付与し、S タイプには回答値の文字列(answer)も付与した。

6. 評価方法(指標とツール)

6.1 書き起こし: CER(文字誤り率)

CER = 編集距離 ÷ 正解文字数。正解は台本そのもの。NFKC 正規化と空白・句読点の除去後に測定 (句読点の位置は音声認識の流儀差であり意味に影響しないため)。無音動画 10 本は対象外。

6.2 検索: 情報検索の標準指標

ハイブリッド検索(BM25 + ベクトル、RRF 統合)の top-5 に対して、hit@1 / hit@3(正解動画のチャンクが 1 位 / 3 位以内)、MRR、seg_hit@1(1 位チャンクの時間範囲が正解場面と重なる)、ans@k(取得チャンク本文に回答値そのものが含まれる — 検索が「当たった」ように見えても本文に値がなければ RAG は答えを生成できない、を測る本検証の中心指標)。

6.3 RAG 回答品質: ragas

RAG 評価の標準ライブラリ **ragas 0.4.3** を使用。検索 top-3 をコンテキストに gpt-5.4-mini で日本語回答を生成し(コンテキスト外は「分かりません」と答える指示)、LLM-as-a-judge(gpt-4.1-mini、温度 0)で 5 指標を測定した: faithfulness(コンテキストへの忠実性)/ answer_relevancy(質問への適合)/ context_precision(上位コンテキストの適合率)/ context_recall(参照回答の根拠の網羅)/ answer_correctness(参照回答との一致)。

7. 結果 1: 書き起こし精度(CER)

0.60%

micro CER(94 本合算)

0.00%

中央値

1.20%

90 パーセンタイル

69

CER 0%(完全一致)の本数

誤りの大半は表記ゆれ(「二」→「2」「プリンタ」→「プリンター」等)で、意味を変える誤認識は同音のドメイン語(「社給」→「社級」「有線」→「優先」「上長」→「冗長」等)に集中する。実運用ではカスタム語彙・後段の用語正規化で対処する典型パターンである。

CER 上位(誤りが多い動画)

動画	CER	編集数 / 文字数
g67-portal-cancel	17.99%	25 / 139
slide-files	10.58%	20 / 189
newhire-orientation	1.86%	8 / 431
password-reset	1.83%	5 / 273
g06-elearn-config	1.75%	3 / 171

外れ値の内訳(上位 2 本は個別に原因を確認済み)。g67-portal-cancel(17.99%)は末尾ステップの発話 25 文字が書き起こしから欠落したもので、本検証で唯一観測した発話の取りこぼし(末尾セグメント)。slide-files(10.58%)は台本に含まれる記号・英字(「日付_案件_内容」「v1, v2」)の読み上げ形(アンダーライン等)との差で、正解データ側のアーティファクトであり CU の誤りではない。これらを除く動画の CER はおおむね 2% 未満に収まる。

注意: 本データセットは合成音声(単一話者・雑音なし・鮮明な画面)であり、CER は実収録動画に対する上限性能として読むこと。実案件では実動画でのパイロット測定を挟む。

8. 結果 2: 検索精度

8.1 構成 A~D の比較(全 111 クエリ)

構成	hit@1	hit@3	MRR	seg_hit@1	ans@1(S)	ans@3(S)
A: 書き起こしのみ	0.577	0.784	0.682	0.369	0.000	0.000
B: prebuilt-videoSearch	0.658	0.847	0.754	0.477	0.082	0.115
C: 日本語カスタムフィールド	0.784	0.955	0.861	0.604	0.590	0.738
D: C + screenTexts 重み付け	0.703	0.955	0.817	0.532	0.557	0.754




図 2: 検索指標の構成間比較(全クエリ)。




図 3: 画面のみ情報(S タイプ 61 問)の回答値含有率。書き起こしのみ(A)では原理的に取れず、カスタムフィールド(C/D)で大きく改善する。

8.2 構成 C で ans@3 を外した S クエリの内訳(16 / 61 問)

原因	件数	意味・対策
検索ミス(正解動画が top-3 外)	5	ハイブリッド検索の改善余地(クエリ拡張・上位 k 拡大)
正解動画は当たったが、値を持つセグメントが top-3 外	9	同一動画の別セグメントが上位を占有。動画単位の重複排除や「動画→セグメント」の 2 段検索で改善可能
値そのものが CU 出力に無い(転記漏れ)	2	真の視覚転記漏れは S 61 問中 2 件のみ。CU は 59 / 61 問(96.7%)で画面の値を出力できていた

8.3 動画形態別(構成 A vs C)

構成	形態	n	hit@1	hit@3	MRR
A: 書き起こしのみ	長尺・複数章構成	4	1.000	1.000	1.000
A: 書き起こしのみ	ナレーション付き UI 操作	93	0.581	0.828	0.707
A: 書き起こしのみ	無音・テロップのみ	8	0.000	0.000	0.000
A: 書き起こしのみ	スライド講義型	6	1.000	1.000	1.000
C: 日本語カスタムフィールド	長尺・複数章構成	4	0.750	1.000	0.875
C: 日本語カスタムフィールド	ナレーション付き UI 操作	93	0.774	0.946	0.852
C: 日本語カスタムフィールド	無音・テロップのみ	8	0.750	1.000	0.854
C: 日本語カスタムフィールド	スライド講義型	6	1.000	1.000	1.000

無音(テロップのみ)動画は書き起こしが空になるため、構成 A では索引にすら入らない。視覚情報を扱う構成 C で初めて検索対象になる点が形態別比較の要点である。

9. 結果 3: RAG 回答品質(ragas)

ragas 指標	構成 A(書き起こしのみ)	構成 C(カスタムフィールド)
faithfulness	0.973	0.790
answer_relevancy	0.200	0.279
llm_context_precision_with_reference	0.519	0.782
context_recall	0.414	0.838
answer_correctness	0.432	0.561




図 4: ragas 5 指標の比較(n=111、判定 LLM: gpt-4.1-mini)。

読み方の注意(指標の性質)。 (1) 構成 A の faithfulness が高い(0.97)のは、コンテキストに根拠が無いとき「分かりません」と答える設計のため (A の回答の 59/111 問が「分かりません」、C は 38/111 問)。無回答は捏造ゼロ=忠実と評価されるので、faithfulness は **context_recall / answer_correctness とセットで読む必要がある**。(2) answer_relevancy は「分かりません」型の回答を 0 と評価する仕様のため両構成とも低く出る。構成間の相対比較にのみ使用する。(3) 総合すると、C は A に対して context_precision +0.26 / context_recall +0.42 / answer_correctness +0.13 と、「答えるべき質問に答えられる」方向で一貫して優位。

10. 処理時間

項目	prebuilt-videoSearch	カスタム(videoSearchJa)
解析本数	99	99
1 本あたり中央値	31 秒	41 秒
1 本あたり p90	61 秒	51 秒
実時間比(中央値/動画長)	0.84 倍	0.92 倍

CU の解析は非同期(Operation-Location ポーリング)。バッチ取り込みでは並列実行できるが、紐づけた補完モデルデプロイの TPM が律速になる(§ 11)。

11. 実装上の注意点(検証中に実際に踏んだ詰まりどころ)

#	事象	対処
1	defaults へのモデル登録をモデル名で行うと、PATCH は成功するのに analyze が失敗する	prebuilt アナライザーが参照する エイリアス名 (prebuilt-analyzer-completion-mini 等)をキーに登録する。エラーは analyze 時まで遅延する
2	カスタムアナライザーの base に prebuilt-videoSearch を指定すると 400	base に使えるのは基底 4 種のみ(prebuilt-video 等)
3	親アナライザーの fieldSchema がセグメントに適用されない	フィールドを持つサブアナライザーを作り、親の contentCategories から参照する 2 段構成にする (公式 analyzer-reference に記載)
4	カスタムアナライザーで models.completion を省くと analyze が失敗	モデル名(デプロイ名ではない)を明示する
5	既存アナライザー ID への PUT は変更が黙って無視される	実質イミュータブル。更新は DELETE → 再作成
6	解析の並列実行で 429(RateLimit)が analyze の失敗として返る	CU 自体でなく補完デプロイの TPM 律速。クォータ増強+指数バックオフ再試行を実装
7	omitContent: true とフィールド定義は併用不可(400)	omitContent: false にする
8	defaults・カスタムアナライザーは Bicep に乗らないデータプレーンの状態。環境再作成時に登録を忘れると解析が全滅する	セットアップスクリプトに defaults 登録(エイリアス込み)とアナライザー作成を含めて固定化
9	ソフト削除 → パージ → 同名再作成 したリソースでは CU の解析が「deployment or resource was not found(404)」で失敗し続けた(外部からのモデル呼び出しは正常)	別名でリソースを作り直すと即解消。検証環境の再作成は同名を避ける(公式未記載の実測)
10	フレームは約 1 FPS・512×512 に縮小され、小さい文字が落ち得る(公式記載)	本検証の画面文字(25~40px/720p)は全件読めた。実動画では文字サイズに注意

12. 制約と限界

- **合成データ**: 実収録より条件が良い(単一話者・雑音なし・非圧縮画面)。CER・画面文字の転記率は上限性能。実案件では実動画でパイロット測定を行うこと(本パイプラインは流用可能)。
- **規模**: 104 本・111 クエリでの測定。数千本規模ではベクトル索引のチューニング(フィルタ・セマンティックランカー等)の追加検討が必要。

- **LLM-as-a-judge:** ragas の値は判定 LLM(gpt-4.1-mini)に依存する相対比較として読むこと。構成間の差 (A vs C)の比較には有効だが、絶対値の閾値運用には向かない。
- 単価は変動するため、コスト見積もりは最新の料金ページ(付録)で確認すること。

13. 実装チームへの推奨事項

1. 採用構成は **C**(日本語カスタムフィールド、2 段アナライザー)。top-3 を LLM に渡す標準的な RAG で $\text{ans@3} = 0.74$ 。D(フィールド重み付け)は動画間の切り分けを悪化させるトレードオフがあり、top-1 しか使えない場合のみ検討。
2. 書き起こしの別実装(Speech SDK 等)は不要。CU の出力(transcriptPhrases)をそのまま使う。
3. チャンク単位は CU のセグメント。時間範囲(startTimeMs/endTimeMs)をメタデータに持たせ、回答には「動画名 + 分:秒」を引用させる。
4. フィールド設計 3 点セット: 日本語要約(summaryJa)/ 画面内テキストの一字一句転記(screenTexts) / 操作列挙(uiActions)。description は「ミニプロンプト」として具体例を列挙する。
5. バッチ取り込みは並列数と補完デプロイの TPM クォータをセットで設計し、429 再試行を必ず入れる。
6. 同音ドメイン語の誤認識(社給→社級 等)に備え、用語正規化辞書を後段に用意する。

付録: 参照資料

- CU REST クイックスタート: learn.microsoft.com/azure/ai-services/content-understanding/quickstart/use-rest-api
- CU what's new(GA 2025-11-01): learn.microsoft.com/azure/ai-services/content-understanding/whats-new
- CU video 概要(1 FPS / 512×512 等の制約): learn.microsoft.com/azure/ai-services/content-understanding/video/overview
- CU アナライザーリファレンス(contentCategories / fieldSchema): learn.microsoft.com/azure/ai-services/content-understanding/concepts/analyzer-reference
- CU 言語・リージョン対応: learn.microsoft.com/azure/ai-services/content-understanding/language-region-support
- AI Search ハイブリッド検索(RRF): learn.microsoft.com/azure/search/hybrid-search-overview
- AI Search スコアリングプロファイル: learn.microsoft.com/azure/search/index-add-scoring-profiles
- ragas ドキュメント: docs.ragas.io
- CU 料金: azure.microsoft.com/pricing/details/content-understanding/
- データセット調査(PsTuts-VQA / VideoGUI): github.com/adobe-research/PsTuts-VQA-Dataset ほか。詳細は docs/dataset-research.md

本レポートの数値はすべてリポジトリ `labs/cu-video-rag/logs/` の評価出力から機械的に転記したもの (gen_report.py)。再現手順は README.md を参照。